

基于 PSO - GRU 的股票价格预测方法

史浩杰

(杭州电子科技大学, 浙江 杭州 310018)

摘要: 股票价格预测是量化投资领域的重要研究内容, 准确的股票价格预测有助于投资者制定更加合理的投资决策。针对传统循环神经网络模型超参数依赖人工经验设定、预测精度受限的问题, 本文提出一种基于粒子群优化算法 (Particle Swarm Optimization, PSO) 和门控循环单元网络 (Gated Recurrent Unit, GRU) 的股票价格预测方法。首先, 从股票历史交易数据中提取开盘价、最高价、最低价、收盘价、成交量、涨跌幅等基础特征, 并构建 MA5、MA20、RSI、MACD 和 KDJ 等技术指标; 随后利用 PSO 算法对 GRU 模型的关键超参数进行自动寻优; 最后构建 PSO - GRU 预测模型实现股票收盘价预测。为了验证模型性能, 选取 10 支 A 股上市公司近十年的历史交易数据进行实验, 并与 LSTM、GRU 和 LSTM - Attention 模型进行对比。实验结果表明, PSO - GRU 模型在 MAE、MAPE、MSE 和 RMSE 等评价指标上均取得最优结果, 说明 PSO 算法能够有效提升 GRU 模型的预测性能, 具有较好的应用价值。

关键词: 股票价格预测; 粒子群优化; GRU; 深度学习; 时间序列预测

Stock Price Forecasting Method Based on PSO - GRU

SHI Haojie

(Hangzhou Dianzi University, Hangzhou 310018, China)

Abstract: Stock price prediction is a crucial research topic in the field of quantitative investing, as accurate predictions aid investors in making more rational investment decisions. Addressing the limitations of traditional recurrent neural network models—namely their reliance on manual hyperparameter tuning and constrained prediction accuracy—this paper proposes a stock price forecasting method based on the Particle Swarm Optimization (PSO) algorithm and Gated Recurrent Unit (GRU) network. First, fundamental features such as opening prices, highest prices, lowest prices, closing prices, trading volumes, and price fluctuations are extracted from historical stock transaction data, alongside technical indicators like MA5, MA20, RSI, MACD, and KDJ. Subsequently, the PSO algorithm is employed to automatically optimize key hyperparameters of the GRU model. Finally, a PSO - GRU forecasting model is constructed to predict stock closing prices. To validate model performance, historical transaction data from 10 A - share listed companies over the past decade were selected for experiments, with comparisons made against LSTM, GRU, and LSTM - Attention models. The results demonstrate that the PSO - GRU model achieves the best performance across evaluation metrics such as MAE, MAPE, MSE, and RMSE, indicating that the PSO algorithm effectively enhances the predictive capabilities of the GRU model, showcasing strong practical value.

Keywords: stock price prediction; particle swarm optimization; GRU; deep learning; time series forecasting

引言

随着我国资本市场的不断发展, 股票投资已经成为居民财富管理和资产配置的重要方式之一。股票市场作为国民经

济运行的重要组成部分, 其价格波动不仅反映企业经营状况和市场供求关系, 也在一定程度上反映宏观经济的发展趋势。然而, 股票市场具有高风险、高收益和强随机性等特点, 受到宏观经济环境、行业发展状况、市场情绪以及投资者行为等多种

因素的共同影响,导致股票价格呈现出复杂的非线性和时变特征。因此,如何准确预测股票价格走势,一直是金融工程、量化投资以及人工智能领域的重要研究课题。

早期股票价格预测主要依赖于统计学方法,如自回归模型(AR)、移动平均模型(MA)、自回归滑动平均模型(ARMA)以及自回归积分滑动平均模型(ARIMA)等。这些方法能够在一定程度上刻画时间序列数据的线性特征,但对于股票市场中复杂的非线性关系和长期依赖特征的建模能力有限,因此预测精度受到较大限制。

近年来,随着人工智能技术的快速发展,深度学习方法凭借其强大的特征提取能力和非线性映射能力,在金融时间序列预测领域得到了广泛应用。循环神经网络(Recurrent Neural Network, RNN)能够利用历史信息对时间序列进行建模,但存在梯度消失和梯度爆炸等问题。为了解决这一问题,长短期记忆网络(Long Short-Term Memory, LSTM)和门控循环单元网络(Gated Recurrent Unit, GRU)被相继提出。其中,GRU通过引入更新门和重置门机制,在保留长期记忆能力的同时减少了模型参数数量,具有训练速度快、收敛稳定以及预测性能优良等优点,因此被广泛应用于股票价格预测任务。

尽管GRU模型能够有效捕捉股票价格序列中的时序依赖关系,但其预测性能在很大程度上依赖于隐藏层神经元数量、网络层数、学习率、Dropout率以及Batch Size等超参数的设置。传统方法通常采用经验设定或人工反复试验的方式选择超参数,不仅耗时较长,而且难以保证获得全局最优解,从而影响模型的预测效果。因此,如何自动寻找最优超参数组合,进一步提升GRU模型的预测性能,成为当前研究的重要方向之一。

粒子群优化算法(Particle Swarm Optimization, PSO)是一种模拟鸟群觅食行为的群体智能优化算法,具有结构简单、参数较少、收敛速度快以及全局搜索能力强等优点。PSO通过粒子之间的信息共享不断更新搜索方向,能够在复杂搜索空间中快速寻找到较优解,因此被广泛应用于神经网络参数优化、特征选择以及组合优化等领域。将PSO与GRU模型相结合,利用PSO自动搜索GRU模型的关键超参数,有望进一步提高股票价格预测精度。

基于此,本文提出一种基于粒子群优化算法和门控循环单元网络的股票价格预测方法(PSO-GRU)。首先,从股票历史交易数据中提取开盘价、最高价、最低价、收盘价、成交量和

涨跌幅等基础交易特征,并构建MA5、MA20、RSI、MACD以及KDJ等技术指标;随后采用PSO算法对GRU模型的关键超参数进行自动寻优;最后利用最优参数训练GRU模型完成股票价格预测。为了验证所提方法的有效性,本文选取10支A股上市公司近十年的历史交易数据进行实验,并与LSTM、GRU以及LSTM-Attention模型进行对比分析。实验结果表明,PSO-GRU模型在MAE、MAPE、MSE和RMSE等评价指标上均优于对比模型,验证了所提方法在股票价格预测任务中的有效性和优越性。

一、基于PSO-GRU的股票价格预测方法

(一)数据来源与预处理

本文股票价格数据来源于东方财富网。为了保证实验结果的可靠性和普适性,选取10支A股上市公司股票作为研究对象,时间范围覆盖近十年的日交易数据。原始数据包括开盘价(Open)、最高价(High)、最低价(Low)、收盘价(Close)、成交量(Volume)以及涨跌幅(ChangePct)等基础交易信息。

由于股票市场数据存在量纲差异较大、波动范围不一致等问题,若直接输入神经网络进行训练,容易导致模型收敛速度下降甚至训练不稳定。因此,在模型训练之前,需要对原始数据进行预处理。首先对数据按照交易日期进行升序排列,并删除缺失值和异常值;随后采用Min-Max归一化方法将所有特征映射到[0,1]区间,以消除不同特征之间的量纲影响。归一化公式如下:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

其中, X 表示原始数据, $X_{\max}$ 和 $X_{\min}$ 分别表示样本中的最大值和最小值, X_{norm} 表示归一化后的数据。

为了构建时间序列预测样本,本文采用滑动窗口方式构造训练数据。设时间窗口长度为LOOKBACK,则利用前LOOKBACK个交易日的数据预测下一交易日的收盘价格。

(二)技术指标构建

股票价格变化不仅受到历史价格的影响,同时还受到市场趋势和技术形态等因素的影响。为了提高模型对股票市场信息的表达能力,在基础交易特征的基础上进一步构建技术指标特征。

本文选取移动平均线(MA)、相对强弱指标(RSI)、指数平滑异同移动平均线(MACD)以及随机指标(KDJ)等常用技术指标。其中,MA5和MA20分别反映股票价格的短期趋势和中

长期趋势;RSI 用于衡量股票价格的超买超卖状态;MACD 能够反映市场趋势变化;KDJ 指标能够反映市场买卖力量的强弱变化。

最终构建的输入特征如表 1 所示,共计 11 个输入特征。

表 1 股票预测输入特征

类别	特征名称
基础交易特征	Open、High、Low、Close、Volume、ChangePct
技术指标特征	MA5、MA20、RSI、MACD、KDJ_J

(三) GRU 模型

门控循环单元(Gated Recurrent Unit, GRU)是一种改进的循环神经网络结构,通过引入更新门(Update Gate)和重置门(Reset Gate)解决传统 RNN 模型存在的长期依赖问题。与 LSTM 相比,GRU 结构更加简单,参数数量更少,训练速度更快,在时间序列预测任务中表现出较好的性能。

更新门用于控制历史信息保留程度,其计算公式如下:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z) [z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)]$$

重置门用于控制历史状态信息的遗忘程度,其计算公式如下:

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

候选隐藏状态计算公式如下:

$$h_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h)$$

最终隐藏状态更新公式如下:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot h_t$$

其中, x_t 表示当前输入, h_{t-1} 表示上一时刻隐藏状态, σ 表示 SIGMOID 激活函数, $\odot$ 表示逐元素乘法运算。




图 1 GRU 网络结构

(四) PSO 算法

粒子群优化算法(Particle Swarm Optimization, PSO)是一种典型的群体智能优化算法,通过模拟鸟群觅食行为实现全局最优搜索。PSO 算法中的每个粒子代表一个候选解,粒子通过不断学习个体历史最优位置和群体历史最优位置更新自身位置,从而寻找最优解。

粒子速度更新公式如下:

$$v_i^{t+1} = wv_i^t + c_1 r_1 (p_i - x_i^t) + c_2 r_2 (g - x_i^t)$$

粒子位置更新公式如下:

$$x_i^{t+1} = x_i^t + v_i^{t+1}$$

其中, v_i^t 表示粒子速度, x_i^t 表示粒子位置, p_i 表示个体最优位置, G 表示全局最优位置, w 表示惯性权重, c_1 和 c_2 分别表示学习因子, r_1 和 r_2 为随机数。

在本文中,每个粒子对应一组 GRU 超参数组合,包括时间窗口长度、隐藏层神经元数量、网络层数、Dropout 率、学习率、权重衰减系数以及 Batch Size 等参数。以验证集预测误差作为适应度函数,不断迭代搜索最优超参数组合。




图 2 PSO 优化过程图

(五) PSO - GRU 股票价格预测模型

为了进一步提高股票价格预测精度,本文将 PSO 算法与 GRU 模型相结合,构建 PSO - GRU 股票价格预测模型。首先对股票历史交易数据进行预处理,并计算技术指标特征;随后利用 PSO 算法对 GRU 模型关键超参数进行搜索优化;最后采用最优参数训练 GRU 模型,实现股票价格预测。

PSO - GRU 模型整体流程如图 3 所示。




图 3 PSO - GRU 股票价格预测模型

其中,模型评价指标采用平均绝对误差(MAE)、平均绝对百分比误差(MAPE)、均方误差(MSE)和均方根误差(RMSE)等指标,以综合衡量模型预测性能。

二、实验结果与分析

(一)数据集与实验环境

为了验证本文所提 PSO-GRU 模型在股票价格预测任务中的有效性,选取 10 支 A 股上市公司股票作为研究对象,为保证样本行业覆盖性,选取金融、白酒、新能源、医药、家电、通信设备、人工智能及消费电子等多个行业龙头企业作为研究对象,股票历史交易数据来源于东方财富网。数据时间范围覆盖近十年的日交易数据,包含开盘价(Open)、最高价(High)、最低价(Low)、收盘价(Close)、成交量(Volume)以及涨跌幅(ChangePct)等基础交易信息。

在基础交易特征的基础上,进一步构建 MA5、MA20、RSI、MACD 以及 KDJ 等技术指标,共形成 11 维输入特征。采用滑动窗口方式构建时间序列样本,并利用前 Lookback 个交易日的数据预测下一交易日的收盘价格。实验环境配置如表 2 所示。

表 2 实验环境配置

项目	配置
操作系统	macOS
开发语言	Python 3.11
深度学习框架	PyTorch
数据处理工具	Pandas、NumPy
模型优化算法	PSO
基础预测模型	GRU

数据集按照时间顺序划分为训练集、验证集和测试集,其中训练集占 70%,验证集占 10%,测试集占 20%。

(二)评价指标

为了全面评价模型预测性能,本文采用平均绝对误差(MAE)、平均绝对百分比误差(MAPE)、均方误差(MSE)和均方根误差(RMSE)作为评价指标。

平均绝对误差(MAE)定义如下:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

平均绝对百分比误差(MAPE)定义如下:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

均方误差(MSE)定义如下:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

均方根误差(RMSE)定义如下:

$$RMSE = \sqrt{MSE}$$

其中, y_i 表示真实值, $\hat{y}_i$ 表示预测值, n 表示样本数量。

上述指标越小,说明模型预测精度越高。

(三)参数设置

为了保证实验公平性,本文选取 LSTM、GRU 和 LSTM-Attention 作为对比模型,并与本文提出的 PSO-GRU 模型进行比较。

其中,LSTM、GRU 和 LSTM-Attention 采用固定参数配置进行训练;PSO-GRU 利用粒子群优化算法自动搜索最优超参数组合。PSO 搜索参数包括时间窗口长度(Lookback)、隐藏层神经元数量(Hidden Size)、网络层数(Num Layers)、Dropout 率、学习率(Learning Rate)、权重衰减系数(Weight Decay)以及 Batch Size 等。

PSO 算法参数设置如表 3 所示。

表 3 PSO 参数设置

参数	取值
粒子数量	12
最大迭代次数	10
惯性权重	0.7
学习因子(C_1)	1.5
学习因子(C_2)	1.5

表 4 PSO 搜索空间

参数	搜索范围
Lookback	10 ~ 60
Hidden Size	32 ~ 192
Dropout	0.1 ~ 0.5
Learning Rate	1e-4 ~ 1e-2
Batch Size	16 ~ 128

表 5 PSO 搜索得到的最优超参数组合

股票名称	Lookback	Hidden Size	Layers	Dropout	LR	Weight Decay	Batch Size
平安银行	10	64	1	0.1	0.002	0	32
贵州茅台	60	32	1	0	0.001	1.00E-05	16
宁德时代	40	64	1	0.3	0.0005	1.00E-05	64
恒瑞医药	60	32	1	0	0.002	1.00E-06	16
美的集团	15	192	1	0.1	0.0008	1.00E-06	16
中信证券	20	128	1	0.3	0.0005	1.00E-06	32
中兴通讯	20	160	2	0.2	0.001	1.00E-05	16
比亚迪	60	128	1	0	0.002	0	64
科大讯飞	20	32	1	0.2	0.002	1.00E-06	64
立讯精密	30	192	1	0.2	0.001	1.00E-06	32

表 5 给出了 PSO 算法在 10 支股票数据集上搜索得到的最优超参数组合。可以看出,不同股票对应的最优参数存在明显差异,其中时间窗口长度(Lookback)主要分布在 10~60 之间,隐藏层神经元数量主要分布在 32~192 之间,说明不同股票的价格波动特征具有一定差异。PSO 算法能够根据不同股票数据特征自动搜索适合的网络结构和训练参数,从而提高模型

预测性能。

(四) 对比实验结果

为了验证本文所提 PSO-GRU 模型的预测性能,选取 LSTM、GRU 以及 LSTM-Attention 模型作为对比模型,在 10 支 A 股股票数据集上进行实验。表 6 给出了各模型在不同股票上的预测结果,表 7 给出了各模型在全部股票上的平均预测结果。

表 6 不同模型在 10 支股票上的预测结果

股票名称	模型	MAE	MAPE(%)	MSE	RMSE
平安银行	LSTM	0.119	1.051	0.027	0.163
平安银行	GRU	0.129	1.139	0.03	0.172
平安银行	LSTM-Attention	0.281	2.479	0.128	0.358
平安银行	PSO-GRU	0.105	0.927	0.024	0.155
贵州茅台	LSTM	20.686	1.404	1104.98	33.241
贵州茅台	GRU	16.671	1.131	710.499	26.655
贵州茅台	LSTM-Attention	44.303	3.003	3784.838	61.521
贵州茅台	PSO-GRU	15.963	1.087	577.526	24.032
宁德时代	LSTM	7.394	2.266	95.607	9.778
宁德时代	GRU	9.751	3.065	147.36	12.139

宁德时代	LSTM + Attention	14.936	4.888	346.427	18.613
宁德时代	PSO + GRU	7.261	2.235	100.206	10.01
恒瑞医药	LSTM	0.917	1.706	1.57	1.253
恒瑞医药	GRU	0.902	1.677	1.54	1.241
恒瑞医药	LSTM + Attention	2.064	3.74	7.148	2.674
恒瑞医药	PSO + GRU	0.85	1.577	1.449	1.204
美的集团	LSTM	0.963	1.31	1.712	1.308
美的集团	GRU	0.863	1.176	1.496	1.223
美的集团	LSTM + Attention	2.303	3.113	9.213	3.035
美的集团	PSO + GRU	0.801	1.092	1.288	1.135
中信证券	LSTM	0.4	1.476	0.435	0.66
中信证券	GRU	0.369	1.366	0.356	0.597
中信证券	LSTM + Attention	0.558	2.054	0.711	0.843
中信证券	PSO + GRU	0.359	1.332	0.336	0.579
中兴通讯	LSTM	0.802	2.155	1.386	1.177
中兴通讯	GRU	0.783	2.098	1.378	1.174
中兴通讯	LSTM + Attention	1.335	3.656	3.64	1.908
中兴通讯	PSO + GRU	0.789	2.114	1.38	1.175
比亚迪	LSTM	7.799	5.051	352.819	18.783
比亚迪	GRU	6.437	3.625	247.335	15.727
比亚迪	LSTM + Attention	18.486	11.287	1244.807	35.282
比亚迪	PSO + GRU	5.049	2.851	163.619	12.791
科大讯飞	LSTM	0.962	1.994	1.758	1.326
科大讯飞	GRU	0.854	1.761	1.432	1.197
科大讯飞	LSTM + Attention	1.651	3.415	4.411	2.1
科大讯飞	PSO + GRU	0.838	1.725	1.384	1.177
立讯精密	LSTM	1.284	2.579	3.742	1.934
立讯精密	GRU	1.155	2.385	3.008	1.734
立讯精密	LSTM + Attention	2.207	4.42	9.715	3.117
立讯精密	PSO + GRU	1.062	2.225	2.306	1.519

表 7 各模型平均预测结果

模型	MAE	MAPE(%)	MSE	RMSE
LSTM	4.133	2.099	156.404	6.962
GRU	3.792	1.942	111.443	6.186
LSTM - Attention	8.813	4.206	541.104	12.945
PSO - GRU	3.308	1.717	84.952	5.378

(五) 结果分析

从表 6 和表 7 可以看出,不同模型在股票价格预测任务中的表现存在明显差异。总体来看,PSO - GRU 模型在 MAE、MAPE、MSE 和 RMSE 四项评价指标上均取得最优结果,表明该模型能够更加准确地捕捉股票价格变化规律,具有较好的预测性能。

首先,从 LSTM 和 GRU 模型的对比结果来看,GRU 模型整体性能优于 LSTM 模型。其中,GRU 模型的 MAE、MAPE、MSE 和 RMSE 均低于 LSTM 模型。这说明 GRU 结构能够更加有效地学习股票价格序列中的时序依赖关系。相比于 LSTM,GRU 通过更新门和重置门结构对信息进行筛选,在保持长期记忆能力的同时减少了模型参数数量,因此具有更快的训练速度和更好的泛化能力。在股票价格预测这种数据波动较大且存在非线性特征的任务中,GRU 表现出较好的适应能力。

其次,从 GRU 与 PSO - GRU 模型的比较结果来看,引入粒子群优化算法后,模型预测性能得到进一步提升。PSO - GRU 模型的 MAE 由 3.792 降低至 3.308,下降约 12.8%;MAPE 由 1.942%降低至 1.717%,下降约 11.6%;MSE 由 111.443 降低至 84.952,下降约 23.8%;RMSE 由 6.186 降低至 5.378,下降约 13.1%。实验结果表明,PSO 算法能够有效提高 GRU 模型的预测精度。

造成这一结果的主要原因在于,GRU 模型的预测性能高度依赖于超参数设置。传统 GRU 模型通常采用经验法或人工试验法确定隐藏层神经元数量、时间窗口长度、学习率以及 Batch Size 等关键参数,不同参数组合会直接影响模型的收敛速度和预测效果。而 PSO 算法具有较强的全局搜索能力,能够通过粒子之间的信息共享机制不断更新搜索方向,在较大的参数空间内快速寻找到较优解,从而避免人工调参过程中容易出现的局部最优问题。通过对 GRU 模型关键超参数进行自动优化,PSO - GRU 能够获得更加合理的网络结构和训练参

数配置,进一步提升模型预测性能。

从单只股票的实验结果来看,PSO - GRU 模型在平安银行、贵州茅台、恒瑞医药、美的集团、中信证券、比亚迪、科大讯飞和立讯精密等股票上均取得最优结果;在宁德时代和中兴通讯两支股票上,PSO - GRU 模型与 GRU 模型表现接近。说明 PSO 优化策略不仅能够提升整体预测精度,同时具有较好的稳定性和泛化能力。尽管在个别股票上并未取得绝对最优结果,但从全部股票的平均指标来看,PSO - GRU 模型仍然取得了最佳综合性能。

此外,LSTM - Attention 模型在本实验中的预测效果明显弱于其他模型。从表 6 可以发现,其 MAE、MAPE、MSE 和 RMSE 均显著高于其他模型。这表明在当前样本规模和特征体系下,引入注意力机制并未带来有效提升。造成这一现象的原因可能在于,股票价格序列本身存在较强的随机波动特征,而当前输入特征维度相对有限,注意力机制增加了模型复杂度和参数规模,反而导致模型更容易产生过拟合,从而影响预测效果。

综合上述分析可以发现,PSO - GRU 模型充分结合了 PSO 算法的全局搜索能力和 GRU 模型的时序建模能力。PSO 负责搜索最优超参数组合,提高模型训练效果;GRU 负责提取股票价格序列中的时间依赖特征,实现价格预测。两者结合能够有效提高模型对股票价格变化规律的学习能力,从而获得更高的预测精度。实验结果验证了本文所提 PSO - GRU 模型在股票价格预测任务中的有效性和优越性。

未来可引入 Transformer、Informer 等新型时序模型,并结合市场情绪数据和宏观经济指标进一步提升预测性能。

参考文献:

[1] 秦研,孔浩铭. 基于机器学习算法的股票价格预测[J]. 汕头大学学报(人文社会科学版),2025,41(07):25 - 34 + 94 - 95.
[2] Shah D, Isah H, Zulkernine F. Stock market analysis: A review and taxonomy of prediction techniques[J]. International journal of finan-

- cial studies, 2019, 7(02): 26.
- [3] 徐幼恩, 罗扬. 基于组合模型的股票预测研究综述[J]. 科技和产业, 2022, 22(11): 214-220.
- [4] 秦传东, 孟立群. 基于VMD-SAPW-LSTM模型的股价预测研究[J]. 智能计算机与应用, 2026, 16(05): 20-27.
- [5] 薛颂东, 童佳荣. 基于二次分解和TCN的多变量股价预测研究[J]. 计算机与数字工程, 2026, 54(01): 17-22.
- [6] 刘美言. 深度学习模型在股价预测中的比较研究[J]. 信息系统工程, 2025(90): 75-78.
- [7] Kumbure M M, Lohrmann C, Luukka P, et al. Machine learning techniques and data for stock market forecasting: A literature review[J]. Expert Systems with Applications, 2022, 197: 116659.
- [8] Mintarya L N, Halim J N M, Angie C, et al. Machine learning approaches in stock market prediction: A systematic literature review[J]. Procedia computer science, 2023, 216: 96-102.
- [9] Li Z, Yu H, Xu J, et al. Stock market analysis and prediction using LSTM: A case study on technology stocks[J]. Innovations in applied engineering and technology, 2023: 1-6.
- [10] Shiri F M, Perumal T, Mustapha N, et al. A comprehensive overview and comparative analysis on deep learning models: CNN, RNN, LSTM, GRU[J]. arXiv preprint arXiv:2305.17473, 2023.
- [11] Ławryńczuk M, Zarzycki K. LSTM and GRU type recurrent neural networks in model predictive control: A Review[J]. Neurocomputing, 2025, 632: 129712.
- [12] Jain M, Saihjpai V, Singh N, et al. An overview of variants and advancements of PSO algorithm[J]. Applied sciences, 2022, 12(17): 8392.
- [13] Ramírez-Ochoa D D, Pérez-Domínguez L A, Martínez-Gómez E A, et al. PSO, a swarm intelligence-based evolutionary algorithm as a decision-making strategy: A review[J]. Symmetry, 2022, 14(03): 455.
- [14] 王宝龙, 王杰, 刘广杰. PSO-BP神经网络模型在改造工程造价预测的应用研究: 以广东省为例[J/OL]. 工程管理学报, 1-8 [2026-06-22].