



学校代码: 10272
学 号: 2022214355

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕士学位论文

MASTER DISSERTATION

论文题目	面向联邦学习的因子选股框架及机制
作者姓名	沈弘皓
院(系所)	信息管理与工程学院
专 业	金融信息工程
指导教师	郑大庆
完成日期	2024 年 2 月 27 日

摘要

随着中国经济高速发展,居民可支配收入与财富存量快速增长,证券以其高风险高回报的特点,逐渐成为投资者资产配置的重要选择。金融投资创新作为市场风险管理的手段之一,在优化金融市场投融资效率能发挥关键性作用。目前,在数理金融和现代计算技术快速迭代背景下,金融创新与科技已深度融合,已经成为助力金融行业高质量发展的力量,量化投资是金融创新的重要组成部分。

目前,因子模型目前已成为金融科技量化投资的主流范式,因子模型离不开投入大量资源发掘因子,因此各方均不愿意透露因子数据,但是各方出于趋利性也希望能获取到更多外部因子数据,综上所述,各方希望达成因子数据“可用而不可见”,这与联邦学习的背景不谋而合。本文设计了基于联邦学习多方合作训练因子模型的流程,并对其合理性、有效性与实践可行性进行探讨。

首先,本文从理论上论证将联邦学习应用于因子模型的合理性,从二者的背景出发,因子公开曝光会导致有效性降低,各方均不愿意公开自身的因子数据,然而各方均希望通过数据合作提升模型性能,因此,需要一种兼顾数据隐私性与可用性的技术,这与联邦学习技术的背景不谋而合。多方合作的因子模型中,各方数据差异性主要体现在因子层面,即数据集的特征的样本空间重合,而特征空间差异较大,符合纵向联邦学习范式。

为了联邦学习应用于因子模型的有效性,本文选取部分经典的股票因子构建因子池,在该因子池特征空间随机抽样,模拟各方数据集。随后在联邦学习框架下,模拟各个参与方参与联邦因子模型训练的过程,并按照预测收益率构建多空对冲投资组合,使用算法包括神经网络、线性模型以及树模型。最终,将联邦因子模型与各方本地单独训练模型进行对比,结果表明无论是模型预测涨跌能力还是最终投资组合绩效,平均而言,联邦因子模型优于各方本地单独训练模型,再一次印证了联邦学习应用于因子模型的合理性与有效性。

多方合作的因子模型牵涉到多方利益,联邦学习的参与方不会无条件地参与学习中,需要一定的激励设计以弥补联邦学习中消耗的资源,本文针对联邦因子模型场景进行演化博弈建模,梳理出利益相关主体,即联邦平台、因子数据提供方以及联邦模型使用方,对三方之间的利益关系进行刻画,分析演化稳定策略的存在性以及存在条件。分析得到四个演化稳定策略,分别对应联邦因子模型合

作机制中发展初期阶段、过渡阶段以及成熟阶段。最后本文对演化系统的影响因素进行分析,通过提升数据提供方正向激励,对正面行为激励与负面行为惩罚,也会改善模型的收敛速度。

关键词: 联邦学习 因子模型 演化博弈 激励机制

Abstract

With the rapid development of China's economy, securities, with its high-risk and high-return characteristics, has become an important choice for investors' asset allocation. As one of the means of market risk management, financial innovation can play a key role in optimising the efficiency of investment and financing in the financial market. At present, financial innovation and science and technology have been deeply integrated, has become the power to help the financial industry high-quality development, quantitative investment is an important part of financial innovation.

At present, the factor model has become the mainstream paradigm of quantitative investment in financial technology, the factor model can not be separated from a large number of resources invested in the discovery of factors, so all parties are not willing to disclose the factor data, but all parties out of the convergence of all parties also hope to obtain more external factor data, to sum up, all parties hope to reach the factor data "available but not visible", which is the same as the federated learning. In summary, the parties want to achieve the factor data "available but not visible", which coincides with the background of federated learning. In this paper, we design a process for training factor models based on federated learning with multi-party cooperation, and discuss its rationality, effectiveness and practical feasibility.

Firstly, this paper theoretically argues the reasonableness of applying federated learning to factor models, starting from the background of the two, the public exposure of the factors will lead to lower validity, and all parties are unwilling to disclose their factor data, however, all parties want to improve the model performance through data co-operation, so a technique that takes into account the data privacy and usability is needed, which coincides with the background of the federated learning technique. In the factor model with multi-party cooperation, the data variability of each party is mainly reflected at the factor level, i.e., the sample space of the features of the dataset overlap while the feature space varies greatly, which is in line with the longitudinal federated learning paradigm.

For the effectiveness of federal learning applied to factor models, this paper selects some classical stock factors to construct a factor pool, and randomly samples in the

feature space of this factor pool to simulate the datasets of all parties. Subsequently, under the federated learning framework, the process of each participant participating in the training of the federated factor model is simulated and a long-short hedge portfolio is constructed according to the predicted return, using algorithms including neural networks, linear models, and tree models. Finally, the results of comparing the federated factor model with the local individually trained models of each party show that the federated factor model outperforms the local individually trained models of each party on average, both in terms of the model's ability to predict upward and downward movements as well as the performance of the final portfolios, which once again confirms the reasonableness and validity of applying federated learning to the factor model.

The factor model with multi-party cooperation involves multi-party interests, and the participants of federal learning will not participate in the learning unconditionally, and certain incentive design is needed to make up for the resources consumed in the federal learning. This paper carries out the evolutionary game modelling for the scenario of the federal factor model, sorts out the stakeholder subjects, i.e., the federated platform, the factor data provider, and the users of the federated model, and carves out the interest relationship among the three parties, and analyse the existence and conditions of evolutionary stabilisation strategies. The existence of evolutionary stabilisation strategies and the conditions for their existence are analysed. Four evolutionary stabilisation strategies are obtained, corresponding to the early stage of development, transition stage and maturity stage of the federal factor model co-operation mechanism. Finally, this paper analyses the influencing factors of the evolutionary system, and improves the convergence speed of the model by increasing the positive incentives of the data provider, and incentivising and penalising the positive behaviours and the negative behaviours.

Key words: Federated Learning Factor Model Evolutionary Game Theory Incentive Mechanism

目 录

第一章 导论.....	1
第一节 研究背景与意义.....	1
一、研究背景.....	1
二、研究意义.....	3
三、研究价值.....	4
第二节 论文框架与方法.....	5
一、论文框架.....	5
二、创新之处.....	5
第二章 概念、理论与研究现状	6
第一节 概念介绍与理论.....	6
一、因子模型.....	6
二、联邦学习.....	7
三、演化博弈.....	9
四、利益相关者理论.....	10
第二节 研究现状.....	11
一、因子模型相关研究.....	11
二、联邦学习实践及激励机制相关研究.....	15
三、研究述评.....	17
第三章 联邦学习因子选股模型有效性分析	18
第一节 联邦学习因子模型场景分析	18
一、联邦学习与因子模型应用场景角度.....	18
二、联邦学习与因子模型技术原理.....	19
第二节 数据处理.....	21
一、数据来源与内容.....	21
二、数据预处理.....	23
三、单个因子效果检验.....	26
第三节 联邦学习模拟多方参与因子模型	26
一、实验设计.....	26
二、测试流程.....	28
第四节 联邦学习因子模型效果评估	29
一、模型判断涨跌能力.....	30
二、组合绩效评估.....	30
第五节 本章小节.....	32
第四章 基于演化博弈联邦学习因子模型可行性分析	34

第一节 博弈主体及其行为分析	34
一、联邦学习因子模型合作机制的利益相关者	34
二、联邦平台、模型使用方、数据提供方三方关系	35
三、利益相关者的行为分析	35
第二节 演化博弈模型构建	36
一、研究假设与参数说明	36
二、复制动态方程建立	39
第三节 系统均衡点以及稳定性分析	41
第四节 算例分析	44
一、发展初期阶段	44
二、过渡阶段	46
三、成熟阶段	48
第五节 演化博弈结果影响因素分析	50
一、奖惩设计的影响	50
二、分成设计的影响	52
第六节 本章小节	52
第五章 总结和研究展望	54
参考文献	55
附录 基于 FATE 框架的联邦学习训练	60

第一章 导论

第一节 研究背景与意义

一、研究背景

随着中国经济高速发展，居民可支配收入与财富存量快速增长，证券以其高风险高回报的特点，逐渐成为投资者资产配置与财富增值的选择之一。此外，上市公司通过发行证券向募集社会资金，不断向实体经济注入新鲜活力，更是金融服务实体经济的重要途径。2019年2月，习近平总书记指出“要正确把握金融本质，平衡好稳增长和防风险的关系，要增强金融服务实体经济能力，要强化创新驱动战略，强化技术创新、模式创新、方法创新，促进金融创新升级”。可以看出，金融投资创新作为市场风险管理的手段之一，在优化金融市场投融资效率能发挥关键性作用。目前，在数理金融和现代计算技术快速迭代背景下，金融创新与科技已深度融合，并共同创造社会价值，其中量化投资作为金融科技创新的一种形式，能够显著提升金融资产的管理效率，已经成为助力金融行业高质量发展的力量(Anagnostopoulos,2018, LEEI,2018)。

在传统的基于基本面分析的投资中，投资者分析宏观环境和市场行情，在茫茫市场中寻找优质企业，然而即使是机构投资者也会面临主观认知受限、信息处理能力有限的不利因素(Barber,Odean,2008)。而量化策略凭借高度程序化的作业，基于统计模型、数据分析算法，从海量的证券中全面筛选投资标的，并自动交易，极大地克服了投资者处理信息能力有限与主观情绪的影响，效率远高于传统人工分析与调研。自20世纪80年代第一支量化基金问世以来，量化投资已经在海外市场发展多年，近年来，随着大数据、人工智能、云计算等技术的蓬勃发展，市场不断涌现新型量化策略。据统计，当前美股量化基金规模已达总市值的10%，成交额占比逾七成；中国目前私募量化基金的规模达到1.61万亿，占私募证券投资基金总市值24%。量化投资已广泛应用于量化选股、算法交易、风险管理以及资产配置，量化投资的发展改变了市场生态，已经证券市场高质量发展中成为一股不可忽视的力量(邵宇等.,2023)。

证券收益率的影响因素一直以来都是金融业界和学术界经久不衰的话题，也是量化投资研究的主要目标之一，其中因子模型解释股票收益率硕果累累，因

子模型已经量化投资领域认可度最高、应用最广泛的模型(侯晓辉,王博,2021)。因子模型最早源于资本资产定价模型(Capital Asset Pricing Model, CAPM)和 Fama 和 French 于 1993 年提出的三因子模型。前者最早解释了均衡市场下,市场因子和资产超额收益的关系(Sharpe,1964),用市场收益因子解释证券超额收益;Fama 和 French 于 1993 年提出三因子模型,即股票收益率受到市场因子、规模因子和成长因子共同决定(Fama, French,1993)。自此,业界和学术界对定价因子开展诸多研究,目前学术界对定价因子的研究主要基于发掘市场异象,即寻找带来超额收益的证券特征(Lee, So,2015)。随后成百上千的股票市场异象和定价因子被发现,大量的定价因子用给传统资产定价模型带来了极大挑战:部分因子之间有较大相似度(Gu 等.,2020),且部分因子之间存在较复杂的非线性关系(Bali 等.,2016);高维定价因子导致难以通过搜索确定预测函数的形式,极大加剧计算资源的消耗。面对如此庞大的因子数量,前美国金融学会主席 Cochrane 甚至戏称其为因子动物园(Factor Zoo),他同时指出目前需要“特殊的研究工具”用来处理高维因子数据(Cochrane,2011)。

为此学术界引入了机器学习方法,从因子池中筛选出持续有效的因子(Jiang 等.,2018),据此预测证券收益并构建投资组合(Harvey 等.,2016, Hou 等.,2019)。从国外发展三十多年经验来看,多因子模型策略凭借高稳定性和广覆盖性成为众多量化投资策略中备受学界和业界关注的热点,而多因子模型与机器学习模型结合更是市场关注的热点。

在实践中,目前业界对多因子模型研究的方向主要集中两个方向:新因子的挖掘与检验、机器学习多因子模型。在新因子的挖掘中,各方根据已有金融知识归纳总结为定价因子,并进行有效性的检验,每一个定价因子都是多因子策略盈利的基础。由于建设因子库耗费大量人力物力,因此各方均不愿他人“搭便车”,不愿意透露其因子数据。此外,当原本未公开的因子被泄漏后,将会导致该因子有效性下降,造成因子数据资产的贬值(McLean, Pontiff,2016),因此,各方均不愿意泄漏因子数据。然而,各方出于趋利性也希望能获取到更多因子,以提升多因子模型策略的收益。可以看出,各方均希望因子数据“可用而不可见”,而联邦学习技术作为一种新兴的机器学习范式,能够在技术上实现数据不离域,同时使用各方数据共同训练模型,达成多方合作共赢局面。目前,金融行业已经开展了诸多联邦学习落地应用。不难看出,多方参与的多因子投资模型非常契合联邦学习应用场景,基于联邦学习的因子投资模型是否有效值得深入探究。此外,已有

研究表明联邦学习的参与方不会无条件地参与学习中，联邦学习上传参数与模型训练均会消耗大量本地资源，如果没有合理设计的激励机制，各方不愿参与其中，只有通过合理设计的激励机制保证各方利益，才能使联邦学习落地应用长期稳定地存续(梁文雅等.,2022)。因此，基于联邦学习的多因子投资模型场景下，多方的合作与激励机制也是一个具有现实意义且值得深入探讨的问题。

本文针对因子投资模型在联邦学习场景中的应用开展研究，验证联邦学习能否提升多因子投资模型性能。此外，通过分析各个参与方成本与收益，建立演化博弈模型并分析联邦学习的因子投资模型能否长期稳定运行，探讨影响其运行的因素，以期对模型落地应用提供建设性意见。

二、研究意义

本文针对量化投资领域因子投资模型在联邦学习场景中的应用开展研究，首先明确多因子模型与联邦学习技术应用的具体场景，首先从二者的原理出发，论证二者结合应用的合理性与可行性，证明联邦学习的技术运用并非臆造，而是在技术原理层面存在合理性。

首先，自从 Fama 和 French 于 1993 年提出三因子模型以来，已有大量的研究发掘市场异象构造因子，因子模型凭借较高的经济可解释性成为金融资产定价领域实证研究的焦点，成为学术界和投资业界广泛使用的方法(马甜等.,2022)。此外，因子模型用于预测股票未来收益属于典型监督学习，机器学习在其中已经得到广泛运用。而联邦学习是一种新兴的机器学习范式，通过多个参与方交换模型参数而非交换数据的方式，从技术上达到“数据不动，模型动”、“数据不跑路，模型多跑路”，实现隐私保护与数据资源共享的目标。基于以上背景，本文的研究首先回答：

(1) 因子投资模型在联邦学习场景中的应用是否具有合理性？本文将从二者的背景出发，结合二者的原理与应用场景论证合理性。

其次，因子投资模型在联邦学习场景中的应用，本文参考以往文献选取选取市场具有代表性的部分因子，构建多因子面板数据，以此模拟多方参与的联邦学习因子模型，构建每期动态预测下一期收益并都见投资组合。基于以上策略在 2014 年-2023 年进行回测，比较各方参与联邦学习和自身数据模型的综合性能差异，从而回答以下问题：

(2) 基于联邦学习技术赋能的因子投资模型是与否有效？即参与联邦学习的各方是否能够通过合作提升自身多因子模型性能？

再者，联邦学习的实际应用中，联邦学习模型的性能取决于高质量且稳定的参与方，各方在联邦学习模型训练过程中，需要消耗大量计算资源和网络资源，联邦学习平台和参与方都需要一定的正向激励，才能确联邦学习推广应用的关键。本文对因子联邦学习投资模型关系进行梳理，构建了三方动态演化博弈模型，从而回答以下问题：

因子投资模型在联邦学习场景中，各个方能否获得公平正向激励，从而使各方长期持续参与？各方长期持续参与的影响因素有哪些，这些变量如何影响？能否据此为该场景的实践提供建设性的意见。

三、研究价值

(1) 理论价值

随着中国金融市场逐渐趋向成熟，金融与科技加速融合创新，量化投资作为其中重要一环，正在加速改变金融二级市场业态。其中因子投资模型是量化投资领域的一颗常青树，有悠久的历史历史和深厚的理论基础，凭借着较高的经济可解释性和可扩展性成为业界和学界研究的热点。随着近年来机器学习的兴起，因子投资模型更是使其加速走向成熟，因子模型+机器学习也成为一种主流范式。目前有许多联邦学习与金融领域结合的研究与落地应用，但是却鲜有人提及因子投资模型和联邦学习相结合，本文通过技术理论与二者的背景，充分阐述了二者结合的合理性。

(2) 实践价值

其次，本文用实验模拟联邦学习场景中的因子投资模型，构造了一套联邦学习因子投资选股策略，并进行在 2014 年-2023 年进行回测，结果表明基于联邦学习的选股策略平均而言优于各个参与方自身策略，证明了因子投资模型在联邦学习场景中的应用的有效性与可操作性。

最后，本文剖析了因子投资模型在联邦学习场景中各方的角色，并据此进行演化博弈建模，对如何构建该场景下各方合作的机制给出定量的理论指导，论证联邦学习场景中因子模型的可行性。此外，从影响博弈结果的参数出发，给出构建合作机制的建议，以期对具体的实践有所帮助。

第二节 论文框架与方法

一、论文框架

本文针对多方合作的联邦学习因子模型进行研究，论文主要分为两大板块，分别是实验模拟联邦因子模型、联邦因子模型合作机制分析。本文研究从以下几个部分开展。

第一章，导论。介绍选题背景，简要阐述因子模型与机器学习结合应用的研究现状以及联邦学习在金融领域的技术运用，引出联邦学习技术对多方合作因子模型的应用合理性。此外，介绍本文研究问题与研究意义，阐述本文研究技术路线。

第二章，概念、理论与研究现状。对本文有关的概念与理论进行介绍，包括因子模型、联邦学习、演化博弈以及利益相关者理论。总结国内外文献，总结学界和业界对因子模型和联邦学习实践的研究现状，为后续研究做铺垫。

第三章，联邦学习因子选股模型有效性分析。首先，具体分析联邦学习与因子选股模型的应用场景与技术原理进行分析，阐述二者结合应用的合理性。此外，构建了联邦学习因子模型选股流程，并使用联邦学习框架进行实验模拟，验证联邦学习合作的因子模型优于各方非合作模型，证明联邦学习因子选股模型有效性。

第四章，基于演化博弈联邦学习因子选股模型可行性分析。针对联邦学习因子模型存在各方复杂的利益关系，本文构建联邦因子模型的演化博弈模型，对该合作机制进行研究，对影响合作机制的影响因素进行分析。

第五章，总结和研究展望。对前文研究进行总结，提出未来研究展望。

二、创新之处

提出联邦学习应用于因子模型的新场景。虽然目前联邦学习在金融业界有诸多应用，但是没有涉及联邦学习应用于多方合作的因子模型训练。本文从理论与实验两个角度论述联邦学习因子选股模型相结合，论证二者结合绝非臆造，而存在合理性与有效性。

研究联邦因子模型的合作机制。对其中利益相关方进行梳理，本文给出了一个联邦因子模型的演化博弈模型，解释联邦因子模型的合作机制，基于演化博弈框架并影响合作的因素进行分析。

第二章 概念、理论与研究现状

第一节 概念介绍与理论

一、因子模型

证券收益率的影响因素一直以来都是金融业界和学术界经久不衰的话题，也是量化投资研究的主要目标之一，其中因子模型解释股票收益率硕果累累，因子模型已经量化投资领域认可度最高、应用最广泛的模型。因子模型理论有清晰的发展脉络。

$$E[R_i] - R_f = \beta_i(E[R_M] - R_f) \quad (2.1)$$

马科维茨于 1952 年提出了均值方差模型，奠定了现代数理金融的第一块基石，其使用均值-方差模型刻画了投资组合的收益与风险之间的数量关系。其首次将投资组合优化问题用转化为一个二次规划问题(Markowitz,1952)，求解二次规划问题得到每一个风险水平对应的组合收益，也即有效边界，该研究也使其在 1990 年获得诺贝尔经济学奖。随后，Sharpe 在马科维茨基础上，提出了资本资产定价模型 Capital Asset Pricing Model, CAPM)，如（1）所示。其指出均衡条件下，即所有投资者都是理性人，投资者在有效边界上选择投资组合，风险资产的收益与风险的数量关系。该模型给出了投资者承担一定风险，需要获取多少风险溢价(Sharpe,1964)。

$$E[R_i^e] = \beta_i \lambda \quad (2.2)$$

$$E[R_i^e] = \alpha_i + \beta_i \lambda \quad (2.3)$$

Ross 于 1976 年在推广了 CAPM 模型，并提出套利定价理论(Arbitrage Pricing Theory, APT)，其通过构建套利组合运用无套利约束，最终用多个风险因子解释证券的超额收益，虽然 Ross 没有给出具体风险因子，但 APT 模型确定了多因子模型(multi-factor models)的形式(Ross,2013)。虽然（2）式给出特定风险资产均衡状态下的预期收益率，但是实际市场中往往存在特殊情况，导致等式两边不相等，时常出现错误定价 α_i ，因此常以（3）表示多因子模型。以此为起点，学术界和业界开启了五十余年轰轰烈烈的资产定价研究与因子投资实践。随后的因子研究基于 APT 的形式，各类因子模型层出不穷，例如 Fama 和 French 三因

子模型、Fama-Carhart 四因子模型、Novy-Marx 四因子模型等。

二、联邦学习

近年来,随着信息产业高速升级与变革,物联网、人工智能等技术已经迈入大规模应用阶段,而数据作为机器学习技术的基石,已经成为不可忽视关键生产要素。数据只有在流通中才能产生价值(Huang 等.,2021),然而数据所有方之间构建数据合作机制困难重重,存在以下数据隐私保护层面的限制:①对于企业部门私有数据,横向来看,不同行业的企业业务数据逻辑不同,难以进行数据的整合与协同;纵向而言,头部企业占据了绝大多数数据资源,中小企业与头部企业处于不对等的市场地位,中小企业亦难以获取这些数据信息。②对于政府机构拥有的公共数据,也蕴含巨大的社会经济价值,但其涉及诸多公民隐私、政府机构数据等敏感信息,因此数据所有方出于安全角度考量,不愿共享数据。③各国已经出台法律限制数据跨企业、跨区域、跨国境的流通,例如欧盟通用数据保护条例(Voigt ,Von dem Bussche,2017)、中国《中华人民共和国数据安全法》。④传统的机器学习方法各方上传数据集中训练,但这与隐私隐私保护的需求存在天然的冲突。

基于以上数据孤岛难题的背景,实现数据多方跨域合作迫切需要一种全新的技术框架。其中,谷歌 2016 年提出的用于预测用户键盘输入的技术路线——联邦学习(Federated Learning, FL)技术逐渐受到关注(McMahan 等.,2017)。传统的集中数据训练的思路是“模型不动,数据动”,而联邦学习技术强调“数据不动,模型动”,即在保证用户数据隐私安全的前提下,各方数据不离域,利用分布在各方的数据共同训练一个高质量模型。假设 N 个参与方 $\{C_1, C_2, \dots, C_N\}$ 参与联邦学习,分别拥有数据集 $\{D_1, D_2, \dots, D_N\}$, 记数据集中 $\{D_1 \cup D_2 \cup \dots \cup D_N\}$ 训练的模型精度为 V_{center} , 通过联邦学习训练的模型精度为 V_{fed} , 存在 $\delta > 0$, 使得 $|V_{center} - V_{fed}| < \delta$, 则称联邦学习性能达到了 δ -精度损失。

联邦学习作为一种新兴的机器学习范式,为多方数据共享的应用提供了全新的解决方案,打破数据孤岛的难题,充分挖掘分布在多方的数据潜在价值。目前,联邦学习虽然没有进入产业的大规模应用阶段,但是已有各个领域应用的相关研究与初步应用,包括联邦医疗应用(Kaissis 等.,2020)、联邦金融信贷风控等(Zheng 等.,2021)。

联邦学习根据各个参与方的特征空间与样本空间可以分为三类(Liu等.,2024), 横向联邦学习(Horizontal Federated Learning, HFL)、纵向联邦学习(Vertical Federated Learning, VFL)以及联邦迁移学习(Federated Transfer Learning, FTL)。

表 2.1 联邦学习分类(横向、纵向、迁移联邦学习)对比

	横向联邦学习	纵向联邦学习	联邦迁移学习
数据集特征	样本空间重叠小, 特征空间重叠大	样本空间重叠大, 特征空间重叠小	样本空间重叠小, 特征空间重叠小
参与方之间交换的数据	模型参数	中间结果	中间结果
参与方保留	本地数据	本地数据与本地局部模型	本地数据与本地局部模型
参与方收获	共享的全局模型	本地局部模型	本地局部模型
是否需要协同推理	否	是	否

(1) 横向联邦学习适用于参与方特征空间重叠较多的情形, 横向联邦学习仅仅使用重叠的特征, 因此也被称为样本划分的联邦学习。横向联邦学习是最早被提出的联邦学习模式, 谷歌用于预测用户键盘输入的算法即奠定了横向联邦学习的雏形, 使其最早得到大规模应用。横向联邦学习常见于同一行业的不同企业, 他们相似的业务逻辑决定了其数据拥有相似的特征空间。

(2) 纵向联邦学习适用于参与方样本空间重叠较多的情形, 纵向联邦学习仅仅使用重叠的样本, 因此也被称为特征划分的联邦学习。纵向联邦学习常见于不同行业的企业, 他们相似的业务逻辑不同导致数据的特征空间差异较大, 而样本空间重叠相对较多。例如, 纵向联邦学习技术在金融信贷风控场景中, 不仅可以在保证用户隐私信息、企业的数据安全, 也可以充分保证企业与政府对自身数据完全的所有权与控制权, 深度结合电子商务平台、金融机构、电信运营商、政府数据等多元数据, 综合建设跨行业、跨区域、跨机构的立体反欺诈系统。

三、演化博弈

博弈论（Game Theory）最早来自于经济学研究，其主要研究多个利益主体间的利益冲突与行为决策，目前广泛应用于人类社会活动分析与自然界生物行为分析，博弈论研究用公式刻画了各主体间的激励关系以及其相互作用，并用数学方法针对各方的利益，求解各方最优行动。在传统的古典经济学与博弈论中，往往假定各方具有完全信息，且各个参与方均是完全的“理性人”，即各方都能掌握全部相关信息并严格按照最大化自身利益的方向行动。然而，随着学界对行为科学的研究逐渐深入，“理性人”假定因其过于严格而受到广泛的质疑。以企业竞争为例，企业不可能掌握全局信息，经济环境与企业自身性质也决定了各方不可能具有完全信息和完全理性(黄凯南,2009)。

演化博弈思想最早思想起源于生物进化论，在经典博弈论和经典经济学的基础上发展而来。与传统博弈不同，其假定各方有限理性，也不要求各方具有完全信息。其中西蒙指出，人做决策并非按照“最优”行动，而是试图达到“满意”的标准。因而，演化博弈的假定更符合自然界与人类社会中各博弈主体实际情况，各个主体多次博弈直到达到动态均衡，有限理性和不完全信息使得演化博弈更加贴近实际(程乐峰等.,2021)。

表 2.2 经典博弈论与演化博弈论研究对比

	经典博弈论	演化博弈论
研究对象	个体	种群
信息假设	完全信息	有限信息
理性假设	完全理性	有限理性
均衡类型	纳什均衡	演化稳定策略
均衡过程	不涉及到达均衡的 调整过程	研究种群到达演化 稳定策略前的动态过程 研究最后演化稳定性
到达均衡的过程	到达均衡不需要时间	种群经过长期调整 与交互才能达到均衡

演化稳定策略（Evolution Stable Strategy, ESS）和复制动态方程（Replicated Dynamic Equation, RDE）是演化博弈中的核心概念。其中 Smith 和 Price 于 1973

年给出了演化稳定策略的数学定义：在两个群体 X 与 Y 中，群体 X 与群体 Y 分别采取策略 s_1 与 s_2 ($s_1, s_2 \in S$, S 具有相同纯策略集个体的混合策略集)，其比例分别为 δ 与 $1 - \delta$ ($0 \leq \delta \leq 1$)； X 与 Y 在竞争中，如果存在一个假设存在 $1 - \delta$ ($0 \leq \delta \leq 1$)，使得 $U[x, \delta x + (1 - \delta)y] > U[y, \delta x + (1 - \delta)y]$ 成立，那么则称其中 s_1 是一个演化稳定策略，其中 $U(x, y)$ 是效用函数 (Smith, Price, 1973)。

演化稳定策略描述了演化博弈的结果，而 Taylor 和 Jonker 提出的复制动态方程通过微分方程描述了演化路径，这一对概念共同解释了博弈方策略向演化稳定策略动态收敛的过程 (Taylor, Jonker, 1978)。某一特定策略在种群中出现的概率随着时间动态变化可以刻画为以下形式：

$$F(x) = \frac{dx_i}{dt} = x_i[f_i(x) - \bar{f}(x)] \quad (2.4)$$

其中 $x_i(t)$ 代表 t 时刻特定策略被选中的概率，采取策略 i 的期望收益为 $f_i(x)$ ，群体的平均期望收益为 $\bar{f}(x)$ 。若策略 i 的期望收益大于全体策略的平均收益，选择该纯策略的概率将持续增加；如若达到期望收益等于平均收益，那么概率将保持不变，达到相对稳定的状态。演化稳定策略要求该策略需要一定的稳健型，稳定点未必是具有此种性质。因此演化稳定策略需要同时满足 $F(x) = \frac{dx_i}{dt} = 0$ 和 $F'(x) < 0$ 。

四、利益相关者理论

利益相关者理论 (Stakeholder Theory) 最早源于公司治理研究，其最早定义是在企业经营管理中“下注”，即通过企业的经营管理活动获取收益或者受到损失的相关方。利益相关者理论于 20 世纪 60 年代，在欧美奉行外部控制型企业治理模式的环境中逐渐兴起，与传统的唯股东论不同，利益相关者理论强调企业的生存和发展离不开外部环境，包括供应商、普通职员、政府、消费者、经销商、债权人等 (付俊文, 赵红, 2006)。企业可以视为一个综合的专业化治理的制度，企业需要为股东利益服务，但股东仅是企业服务的一部分，与企业相关的相关个体与组织同样重要，企业治理不应局限于内部治理，而是通过与利益相关者的绑定，实现企业内部外部联动的共同治理模式 (Kostant, 1999)。Sirgy 将利益相关者进一步划分为内部利益相关者、外部利益相关者和远端利益相关者，其中内部利益相关者包括公司员工、公司管理者以及公司董事会；外部利益相关者包括企业所有者、供应商以及本地社区；远端利益相关者包括消费者、政府有关机构等。通过对具体组织中利益相关者的识别分析，可以更好地识别利益相关者的行为与动

机。随着相关研究的发展,利益相关者其定义扩展为影响组织行为与目标,或者受到组织行为与目标影响的个体或者组织(Sirgy,2002)。越来越多的研究者突破原有的框架,不再将利益相关者研究局限于企业,而是将其扩展到政府、非营利组织等多种组织形式,目前已有诸多研究将利益相关者分析框架应用于涉及多方合作的公共管理议题(高明等.,2016, 胡春华等.,2023, 吴洁等.,2019)。

多方合作的因子模型涉及多个利益相关者,其中联邦平台作为发起合作的联邦组织者,各个参与方通过平台共同训练模型,参与方之间存在竞争与合作、平台与参与方存在监管与博弈,整体协同治理与相互竞争过程也应当充分考虑各方利益,实现各方自身价值与共同价值的共创发展。可以看出利益相关者分析框架适用于多方合作的过程,引入利益相关者分析有助于厘清各方的角色与关系,为后续演化博弈建模提供理论基础。

第二节 研究现状

一、因子模型相关研究

随着套利定价模型的提出,大量中外学者针对因子模型开展研究,相关研究可以分为发掘新因子(或模型)、机器学习方法应用于因子模型。

(1) 发掘新因子与新因子模型

资本资产定价模型 CAPM 用市场因子单个因子解释收益率波动,并将其余波动统一归为非系统性风险,虽然其形式上简单直接,但是人们已经无法忽视 CAPM 无法解释的其他风险因子,市场因子并不能完全解释股票波动。Fama 和 French 在 1993 的论文中,研究公司规模因子和成长因子能否解释他 CAPM 不能解释的收益率,他们基于公司市值与账面市值比构造投资组合,最终形成规模因子和成长因子,并将其加入 CAPM 中从而构造出三因子模型,通过研究发现新增因子能够解释大多数股票的价格差异,说明三因子模型可以更好地解释收益率差异(Fama ,French,1993)。三因子模型能合理地解释一些传统模型无法解释的问题,该模型也逐渐进入大众视野,成为因子模型资产定价研究的第一基准。

但三因子模型为之后因子研究彻底打开了大门,经过学界几十年的不懈努力,大量针对无法解释的市场异象的被发现,例如反转等,其中讨论较多的有 Jegadeesh 和 Titman (1993) 提出的动量效应,即过去表现好的股票未来一段时间表现也较好(Grinblatt 等.,1995)。由于动量很难用之前的模型解释,Carhart 将

动量作为新因子加入三因子模型中从而得到 Fama-Carhart 四因子模型 (Carhart,1997)。Fama 起初虽然没有将动量因子纳入自己的研究中,但其本人在实践中也选用过该因子 (Fama 和 French, 2010), 后来 Fama 也认为动量因子是风险因子中特别重要的因子。学界随后提出了各种因子,其中包括价值因子、截面动量因子、盈利因子、投资因子、管理因子、表现因子、长周期行为因子、短周期行为因子等,均在样本期内表现较好。多因子模型作为研究资产定价最重要的工具之一,不断被优化及完善,Novy-Marx 四因子模型(Novy-Marx,2013)、Stambaugh 和 Yuan 的四因子模型(Stambaugh 等.,2015),以及 Fama 和 French 的五因子模型(Fama,French,2015)。Fama 和 French 通过数据检验发现五因子模型相比于三因子模型和 Carhart 四因子模型解释能力更好,并且之后 Fama 和 French 在多个国家的股市继续沿用五因子模型检验其效果。Hou、Xue 和 Zhang 的 q 因子模型中提到的投资因子与盈利因子也为拓展传统定价模型拓宽了思路 (Hou 等.,2015)。

表 2.3 主流多因子模型

模型	因子类型
Fama-French 三因子模型	市场、价值、规模
Carhart	市场、价值、规模、截面动量
Novy	市场、价值、截面动量、盈利
Fama-French	市场、价值、规模、盈利、投资
Hou-Xue-Zhang	市场、价值、盈利、投资
Stambaugh-Yuan	市场、价值、管理、表现
Daniel-Hirshleifer-Sun	市场、长周期行为、短周期行为

以上的模型大部分属于早期因子模型,不难看出,早期的因子模型更倾向于用若干个定价能力较强的因子解释收益,模型的形式比较简单,可解释性较强,能够清晰地展现各个因子对收益率的影响。随着大数据时代到来,金融数据可得性增强,用于处理高维数据的工具也逐渐增多。随之大量异象因子被发掘,其中

Green 整理了 94 个美股异象因子,并验证其有效性(Green 等.,2017)。Jiang 等人构建了 75 个基于 A 股的企业层面的因子(Jiang 等.,2018)。Qiao 分析了 A 股 231 个异象因子,发现仅有 17%的因子,且有效因子大多是流动性因子和成长性因子(Qiao,2019)。

除了以上因子之外,部分基于另类数据的另类因子也被发掘,这些因子的表现不亚于传统因子。Lee 在 2018 年基于科技公司的专利分布情况,构建了科技公司间的科技关联度,该因子在证实了科技关联度高较高的公司之间的股票收益率存在一定的关系,作者以此构建的科技关联度因子可以获取显著的超额收益(Lee 等.,2019)。Green 在 2019 年研究了员工对公司的评价,作者基于员工在第三方平台上对公司的各项评分,其发现员工评价的变化在短期表现出显著的选股能力,总部员工和现任员工的评价效果更明显,基于此的另类因子也表现优秀(Green 等.,2019)。Da 等人 (2021) 则使用了上投资者对股票的周度评分,研究了投资者过度外推信仰和未来股票收益率之间的负向关系(Da 等.,2021)。部分学者通过对企业财报中的文本数据进行自然语言处理, Cohen (2020) 等人对财报中措辞变化进行研究,措辞变动大的公司往往未来表现不佳,作者通过做多措辞变动小的公司,做空措辞变动大的公司,最终获取了年化 20%的多空收益,表明了措辞变动指标的优秀选股能力(Cohen 等.,2020)。

然而,大量的异象及其对应的因子也引起部分学者对因子有效性的质疑。针对先前发表的 447 个因子,其中 64%的因子不再显著,即使显著的因子也比其最初发表的显著性更低(Hou 等.,2020)。McLean 和 Pontiff 研究了发表在主流期刊的 97 个因子,其中因子样本期外收益相比样本期内平均下降 26%,而因子发表后的收益相比样本期内降低 58%,作者指出前者下降是由于样本期内的过拟合,而发表导致的因子效果降低造成二者相差 32%,作者指出其背后的逻辑是:因子的超额收益本质上是市场的错误定价,而因子被发表,导致市场参与者意识到该因子的错误定价,最终市场修复了这种错误定价。

(2) 因子模型与机器学习

成百上千的股票市场异象和定价因子被发现,极大丰富了因子模型的解释维度,但也给传统资产定价模型带来了极大挑战:①首先,理性情况下,因子模型的因子数目越多,对收益率的解释能力越强,模型的样本内性能越强。②但是,部分因子之间有较高相似度(Gu 等.,2020),且部分因子之间存在较复杂的非线性关系(Bali 等.,2016),导致高维度因子数据存在数据冗余和数据有效性问题③高

维定价因子导致难以通过搜索确定预测函数的形式，极大加剧计算资源的消耗。在大数据时代如此庞大的因子数量对传统的线性计量实证方法提出挑战，以至于前美国金融学会主席 Cochrane 甚至戏称其为因子动物园 (Factor Zoo)，他同时指出目前需要“特殊的研究工具”用来处理高维因子数据(Cochrane,2011)。因此学术界引入机器学习方法，这也给传统的多因子模型资产定价带来非线性范式革命(Chen 等.,2024)。

在确定模型需要的因子后，传统的多因子模型使用线性模型将预测股票收益，然而，线性模型难以捕捉因子间的非线性关系，存在较大局限性，随着人工智能的迅速发展，机器学习技术也被引入多因子模型以替代原有的线性模型。机器学习应用于因子模型可以追溯到 Kim 在 2003 年的研究，作者使用股票因子数据，引入支持向量机算法对股票涨跌进行分类预测，在判断股票涨跌的分类问题上，支持向量机的性能优秀且表现优于神经网络(Kim,2003)。为了处理高维因子数据，部分学者对因子数据降维，Kozak 等人和 Kelly 等人分别运用 PCA 和 IPCA 方法，均发现基于较少的主成分足以很好地预测股票横截面收益率(Kelly 等.,2019, Kozak 等.,2020)。

Gu 在 2019 年将梯度提升树、随机森林、前馈神经网络等机器学习算法加入多因子模型，作者指出因子之间的非线性关系与交互项，机器学习方法正式被引入资产定价的研究(Gu 等.,2020)，学界的一众学者开始尝试将各种机器学习算法通过因子模型引入股票收益率预测。Gu 在 2021 年将自编码器引入因子模型，取得较好的预测效果(Gu 等.,2021)。Chen 等人使用了生成对抗网络进行因子非线性关系分析，在其中判别器和生成器使用长短期记忆模型，对美股进行横截面预测，结果表明构建的组合夏普比率大幅超过基准。

目前也有诸多针对中国 A 股市场的机器学习因子研究，谢合亮和胡迪使用 LASSO 回归和弹性网络回归在 A 股市场基于因子模型进行因子特征工程和确定因子权重，研究发现弹性网络相比传统最小二乘回归筛选有效因子的能力更强，最终获得更高的收益(谢合亮 ,胡迪,2017)。李斌等在 A 股的 96 个异象因子基础上，采用 FC 算法、Lasso 回归、岭回归、弹性网络回归、偏最小二乘回归、支持向量机、梯度提升树、极端梯度提升树、集成神经网络、深度前馈网络、循环神经网络和长短期记忆网络等 12 种机器学习算法，结果表明机器学习模型能够更有效地识别出因子-超额收益的复杂关系，基于以上算法的组合表现更优。Leippold 等人对比了中美市场因子模型预测效果的差异，发现几乎全部的机器

学习模型都表明中国市场预测效果普遍较好，即使是线性模型也能取得较好收益，作者认为 A 股市场散户较多，行为偏差比较严重，导致市场错误定价比较严重，导致市场的可预测性较强(Leippold 等.,2022)。马甜等基于 Chen 等人的方法，使用 GAN-LSTM 对 A 股因子投资进行研究，结果表明该方法不仅适用于美股，在 A 股同样表现优秀(马甜等.,2022)。姜富伟等使用 PCA 和带惩罚项的线性模型，用 A 股基本面因子数据，通过主成分分析和惩罚项的因子特征工程，构建了一套解释性较强的简约因子模型，优于传统定价模型(姜富伟等.,2022)。

随着大量机器学习算法在多因子模型的应用，因子模型与机器学习方法结合量化选股已经成为学界和业界的经典范式。

二、联邦学习实践及激励机制相关研究

因子模型是目前量化选股的主流范式，业界已经基于因子模型开展了广泛的实践与应用。各方的因子库往往作为机密数据不与他方共享。首先，构建因子库需要投入大量资源，持续挖掘新因子，因此各方均不愿意被搭便车。其次，公开因子数据会导致新因子的有效性下降，造成因子数据价值的损失。McLean 和 Pontiff 研究了发表在主流期刊的因子，发现因子公开发表后的有效性相比发表前大幅降低，因子有效性本质来源于市场对股票的错误定价，如果一个有效的因子被曝光，那么套利者会基于该因子交易，使得错误定价减弱，最终导致因子有效性降低(McLean ,Pontiff,2016)；因子数据的公开还会导致因子拥挤，当市场发现某个因子有效时，大量资金涌入该因子的交易，从而出现因子拥挤导致预期收益率降低(Bowles 等.,2023)。出于以上原因，各方不愿意公开自身的因子数据，形成一个个因子数据的“孤岛”，但是各方同样希望能利用他方的因子数据，以提升自身因子模型的性能，而这恰巧符合联邦学习的应用背景，即各方均希望数据“可用而不可得”。

联邦学习实践应用集中数据敏感的领域，包括在医疗领域、政务领域以及金融领域。

（1）联邦学习金融实践

金融业作为数据要素密集型行业，一直以来都是人工智能应用的重要领域，金融机构同构整合多元、异构、跨业态的海量数据，业已构建了大量反洗钱、反欺诈成熟应用。然而，随着各方对训练数据需求激增，数据跨境跨域合作逐渐兴起，这也导致许多隐私数据泄漏事件，各国监管机构纷纷法律法规限制数据跨境

流通。其中金融行业的数据相比其他行业有更严格的管理法律法规,除了国家有关部门出台《数据安全法》、《个人信息保护法》等信息安全的通用性法规以外,还有《银行业金融机构数据治理指引》、《个人金融信息(数据)保护办法》、《金融信息服务管理规定》等针对金融行业数据安全管理的政策性文件。这些相关法规对金融行业敏感数据跨域流动进行限制,因此金融行业对打破数据孤岛的联邦学习技术有较强的需求,金融领域业已开展联邦学习诸多应用实践,涵盖金融智能营销、联邦信贷风控以及反洗钱,集中在保险业与银行业。例如,微众银行开发并开源联邦学习框架 FATE,并开展联邦信贷风控与反洗钱相关应用;光大集团在其金控集团内部建立了针对智能风控、客户迁徙统计、智能营销、量化交易以及指数运算等具体场景的联邦学习平台(向小佳,2022);广州银行推出联邦学习+小微贷款风控和联邦学习+理财产品推荐(陈琨等.,2021);平安科技推出蜂巢联邦智能平台用于保险定价;富数科技通过其联邦学习引擎,整合银行、电信运营商、航信多方数据,涵盖上千万条数据,几千个特征,利用多方数据建模,为银行业消费金融赋能(张潇扬等.,2023)。

(2) 联邦学习激励机制

已有研究表明联邦学习的参与方不会无条件地参与学习中,联邦学习上传参数与模型训练均会消耗大量本地资源,如果没有合理设计的激励机制,各方不愿参与其中,只有通过合理设计的激励机制保证各方利益,才能使联邦学习落地应用长期稳定地存续。保障联邦学习各个参与方公平的利益分配是影响联邦学习实际应用的关键因素,提供高质量数据的用户和低质量用户收到相同的模型,高质量用户不愿被搭便车,因此需要客观衡量各个客户端的实际贡献,形成各方认可的激励机制。

激励机制是指通过特定的方法与管理体制,将员工对组织及工作的承诺最大化。激励机制是所有经济活动的核心,无论对于个人决策还是在更大的制度结构内的合作和竞争(Li 等.,2021, 张宗翔等.,2024)。由于联邦学习模型训练涉及多方参与,且参与方之间在数据质量方面参差不齐,导致用户不愿参与或使其参与到联邦学习中处于不公平的地位,联邦学习参与各方的公平性必须加以考虑。但目前的研究主要集中在改善联邦学习模型性能上,用户加入联邦学习的激励机制的研究相对算法研究数量较少。因此,如何使用户持续参与到联邦学习中,在最大化联邦学习可持续经营的同时最小化用户之间的不公平性,是保证联邦学习被广泛推广与应用的关键。

利用博弈论设计激励机制已展开诸多研究，如 Khan 等提出一种斯塔克尔伯格博弈的方法，可使参与用户有策略的设置局部迭代次数，以最大化其效用，结果表明了该方法在模拟中心服务器和边缘设备端之间交互建模的有效性(Khan 等.,2020)；Hu 等将两阶段斯塔克尔伯格博弈的方法应用于联邦学习服务器和用户的效用，通过求解斯塔克尔伯格均衡，得到二者之间效用最大化策略(Hu ,Gong,2020)；Zhan 等分析了斯塔克尔伯格博弈中斯塔克尔伯格均衡和纳什均衡两个阶段的唯一性，有效解决了激励机制是如何影响中心服务器的效用问题，并提出了基于 DRL 的激励机制，来解决非共享信息面临的独特挑战和联邦学习中贡献评估困难等问题(Zhan 等.,2020)。

三、研究述评

因子模型解释资产收益率有着深厚的理论基础，随着目前大数据时代的到来，金融数据可得性增强，因子数据的维度也急剧增加，用于处理高维数据的工具，特别是机器学习算法也逐渐增多。目前因子模型与机器学习结合，已经成为学界与业界研究的经典模式。

此外，金融业数据跨境跨域流通受到监管限制，数据可用与数据合规之间存在矛盾，为了解决数据孤岛难题，金融领域业已开展联邦学习大量实践。因子模型同样属于金融领域，并且各方对因子数据也存在多方合作的土壤，然而，通过联邦学习进行因子模型的多方合作却被较少提及。

在联邦学习激励机制相关研究中，大量研究主要关注通过算法实现联邦学习的激励机制，较少关注某个具体实践场景中的合作机制，缺乏结合具体实践场景的联邦学习合作机制分析。

第三章 联邦学习因子选股模型有效性分析

本章首先针对联邦学习与因子模型的应用场景进行分析，论述将联邦学习应用于因子模型的合理性与可行性。其次，本章选取了部分经典因子数据，并将其按特征划分为若干个数据集，在联邦学习平台上模拟多方合作的因子模型训练过程，结果表明各方通过参与联邦学习能够获得表现优于仅靠自身数据训练的因子模型。

第一节 联邦学习因子模型场景分析

本节首先论述多因子模型与联邦学习技术应用的具体场景，从二者的原理出发，论证二者结合应用的合理性与可行性，证明联邦学习的技术运用并非臆造，而是在技术原理层面与实际应用层面存在合理性。

一、联邦学习与因子模型应用场景角度

因子模型是目前量化选股的主流范式，业界已经基于因子模型开展了广泛的实践与应用。其中，因子数据是因子模型的基础，只有优秀的、可解释强的因子能提升因子模型性能。因子通过数值描述股票在特定时间点的状态，如图 3.1 所示，每一个因子都代表了数据集的一系列特征，构建因子数据集需要对金融市场的数据进行搜集，发掘能够解释股票收益的潜在特征并归纳整理。有效的因子不仅能预测股票收益，并且能够通过经济学进行解释。不难看出，构建因子库需要投入大量的资源，对市场中的经济现象进行观察与研究，才能得到未被发掘的新因子。

各方的因子库往往作为机密数据不与他方共享。首先，构建因子库需要投入大量资源，持续挖掘新因子，因此各方均不愿意被搭便车。其次，因子模型的效果很大程度上取决于因子的有效性，然而公开因子数据会导致新因子的有效性下降，造成因子数据价值的损失。具体而言，公开因子数据会导致错误定价减弱和因子拥挤。McLean 和 Pontiff 研究了发表在主流期刊的因子，发现因子公开发表后的有效性相比发表前大幅降低，因子有效性本质上来源于市场对股票的错误定价，如果一个有效的因子被曝光，那么套利者会基于该因子交易，使得错误定价减弱，最终导致因子有效性降低(McLean ,Pontiff,2016)；因子数据的公开

还会导致因子拥挤，当市场发现某个因子有效时，大量资金涌入该因子的交易，从而出现因子拥挤导致预期收益率降低(Bowles 等.,2023)。

股票_时间点	因子a	因子b	因子c	股票_时间点	因子a	因子d	因子e
600000_20240221				600000_20240221			
*****				*****			
600001_20240221				600001_20240221			

股票_时间点	因子f	因子g
600000_20240221		

600001_20240221		


图 3.1 各方因子数据示例

出于以上原因，各方不愿意公开自身的因子数据，形成一个个因子数据的“孤岛”，但是各方同样希望能利用他方的因子数据，以提升自身因子模型的性能。理想情况下，更多的有效因子参与训练会提升因子模型性能，各方都希望在不泄漏自身因子数据的前提下，广泛利用他方数据，最终达成多方共赢的局面。而联邦学习作为一种新型分布式隐私机器学习范式，可以解决上述因子数据合作的需求，打破因子“数据孤岛”现象。联邦学习保证各方训练因子数据的安全性，即因子数据不离开本地，各方通过模型梯度交换共同训练因子模型。综上所述，联邦学习运用于在多方合作的因子模型，在应用场景层面存在合理性与可行性。

二、联邦学习与因子模型技术原理

在因子模型的具体场景中，因子数据分布在各个参与方本地，而各方的数据集存在以下特点：首先，各方数据集有相同的样本空间，因子数据的每一个样本对应一只股票，而股票属于公开信息，因此各方样本空间一致；其次，各方都自身的因子池，每一个因子都对应数据集一列特征，各方因子特征属于其保密信息，各方数据特征空间重叠往往较少。因此，从各方数据集的特点考虑，因子模型训练适用于纵向联邦学习技术。

图 3.2 联邦学习应用于因子模型的技术原理



纵向联邦学习中各方特征空间差异较大，各方本地模型亦各不相同，因而无法同横向联邦一样直接聚合，为此，在纵向联邦中各方需要交换中间结果（Intermediate results）而非模型参数，其中包括模型输出结果与梯度数据。纵向联邦学习各方模型纵向联邦技术各个参与方包括一个活跃方（active party）以及若干个被动方（passive party），其中活跃方拥有标签数据，负责全局模型梯度的计算与分发。纵向联邦学习通过隐私保障的实体对齐、隐私保障的参数交换，从技术层面保障各方充分因子数据隐私(Liu 等.,2024)。

算法 1 纵向联邦学习训练过程

- 1: 输入: 学习率 η_1 与 η_2
- 2: 输出: 本地模型 G_i 的参数 $\theta_1, \theta_2, \dots, \theta_K$ 和全局模型 F_k 的参数 Ψ_K
- 3: 参与方 $1, 2, \dots, K$ 初始化参数 $\theta_1, \theta_2, \dots, \theta_K, \Psi_K$
- 4: **for** 全局迭代轮次 $j = 1, 2, \dots$ **do**
- 5: 随机选取一小批样本 $x \in D$
- 6: **for** 参与方 $k = 1, 2, \dots, K$ **do**
- 7: 参与方 k 计算 $H_k = G(x_k, \theta_k)$
- 8: 参与方 k 发送 $\{H_k\}$ 至活跃方 K
- 9: **end for**
- 10: 活跃方 K 更新 $\Psi_K^{j+1} = \Psi_K^j - \eta_1 \frac{\partial l}{\partial \Psi_K}$
- 11: 活跃方 K 计算 $\frac{\partial l}{\partial H_K}$ 并发送到其余被动方
- 12: **for** 参与方 $k = 1, 2, \dots, K$ **do**

```

13:      参与方 $k$ 计算  $\frac{\partial l}{\partial \theta_{i,k}} = \sum_i \frac{\partial l}{\partial H_{i,k}} \frac{\partial H_{i,k}}{\partial \theta_{i,k}}$ 
14:      参与方 $k$ 更新  $\theta_k^{j+1} = \theta_k^j - \eta_2 \frac{\partial l}{\partial \theta_{i,k}}$ 
15:  end for
16: end for

```

隐私保障的实体对齐，首先各方的因子数据集有相同的样本空间，而特征空间往往重叠较少，纵向联邦学习技术模型训练首先需要将各方因子数据对齐，即通过隐私计算求交集将各方数据按照样本 ID 对齐，拼接成一张逻辑上的虚拟表。此外，为了保障模型输出结果与梯度数据在传输过程中不被泄漏，纵向联邦学习引入同态加密技术，例如使用被动方 k 上传加密后的结果 $[[H_k]]$ ，活跃方基于此返回加密后的梯度 $[[\frac{\partial l}{\partial H_k}]]$ 。综上所述，纵向联邦学习通过以上隐私计算技术，能够充分保障因子数据安全性，联邦学习运用于在多方合作的因子模型，在技术原理层面存在合理性与可行性。

第二节 数据处理

一、数据来源与内容

本文数据来自 Wind 数据库，本文选取了 2014 年至 2023 年除了 ST 与退市阶段的 A 股全部上市股票，参考已有的因子模型研究，选取了部分经典的股票因子，其中涵盖了企业估值类因子、企业基本面因子和股票技术面因子。

(1) 构建因子池

低信噪比与非平稳性是金融数据的重要特点，因此在模型中引入先验知识有助于更好地利用金融数据(Nagel,2021)，先验参数、调参依据以及正则化罚项的选取都会影响最终模型性能。面对有效信息含量低的数据，也难以得到优秀的结果，因此基于先验的金融知识对原始金融数据进行提炼尤为关键。在因子模型中，解释能力强的优秀因子背后应当有符合直觉的经济解释，本文选取了经济解释能力较好的几类因子，其中基本面因子能够刻画企业质量，是构建因子的首选。此外，资产价格在市场买卖交易中动态形成，因此反应交易资金面的技术类因子也有较好的解释能力。因此，本文选取因子从以下三个维度出发。

①企业质量维度：企业质量是价值投资最关注的维度，本质上反应出企业创造价值的的能力，只有优质企业才能为股东带来长期稳定的回报。在反应企业质量的基本面维度，从盈利能力、成长能力、资本增值能力和景气度筛选部分因子。

盈利因子反映了企业过去一段时间的盈利能力，其中包含净利率、净资产收益率等；成长类因子反应了企业增长趋势与速率，其中包括营业收入同比增速、净利润同比增速以及营利同比增速；资本增值因子反映了企业资本带来的收益，包括总资产收益率和净资产收益率；对于部分周期性较强的行业，其企业综合盈利能力波动较大，如果净资产收益率指标持续上升，意味着企业综合盈利能力边际改善，企业景气度提升，在未来更有可能表现优秀，因此本文选取净资产收益率变化量和总资产收益率变化量衡量景气度。

②企业估值维度：估值是影响投资收益的重要因素，也是价值投资的重要参考维度，优秀企业的股票如果估值过高，也难以带来的超额收益。估值类因子通过静态的相对估值法，确定企业股票价格是否“便宜”。本文选取了了市盈率、市净率、市销率、股息率、当前市盈率历史分位数。

③技术面维度：资产价格在市场买卖交易中动态形成，技术面因子反映了市场资金的行为，股票基本面因子往往数据更新频率较低，时效性较弱，而技术面因子更新快和基本面因子互为补充，本文加入了换手率因子、动量类因子、流动性因子以及波动率因子。

表 3.1 因子类别及描述

因子维度	因子类别	因子名称
企业质量维度	成长能力	净利润同比增速
		营收同比增速
		营利同比增速
	资本增值因子	单季度净资产收益率
		单季度净资产收益率
	景气度	净资产收益率变化量
		总资产收益率变化量
企业估值维度	估值类因子	市盈率
		市净率
		市销率
		前市盈率历史分位数
	分红类	股息率

技术面维度	换手率因子	前一个月换手率
		前三个月换手率
		前一个月动量
		前一年动量
		长期动量
	动量类因子	过去 20 日涨跌幅绝对值和
		前一个月反转
		前三个月反转
		前一年波动率
	波动率因子	前三个月波动率
	流动性因子	过去 20 日成交总额
		流动性因子

（2）股票样本池

本文选取全体 A 股上市公司作为样本，剔除 ST 股票和退市整理股票，选取 2015 年-2023 年为样本期，期间涵盖了中国股市多个周期，具有较强的代表性。

表 3.2 样本数据描述

市场	样本	频率	总计	开始时间	结束时间	数据量
中国 A 股	除 ST 和退市的全体股票	月	85 个月	2014 年 12 月 31 日	2023 年 3 月 31 日	337507 条

二、数据预处理

（1）异常样本剔除

由于上市公司首次公开发行股票、公司重组以及重新上市的首日不存在涨跌幅限制，时常存在短期错误定价，导致数据出现明显偏离均值的异常收益率，因此本文剔除上市不足三个月的股票。此外，在 A 股市场中如果上市企业出现财务异常或者其他异常情况，证监会将其特别处理（Special Treatment，ST），并被公式退市风险，由于 ST 股票往往业绩普遍较差存在较大的投资风险，且涨跌幅限制不同于非 ST 股票，其收益率特征也不同于其他股票，为了避免少部分 ST

股票对模型的影响，本文剔除每一期的 ST 股票。此外，由于 A 股存在停牌制度，部分股票在此期间数据缺失，因此本文也选择剔除停牌股票。




图 3.3 数据集中的有效样本

(2) 数据清洗

首先，对缺失值进行处理，如果某条数据特征缺失过半则直接删去，缺失特征较少则采取均值填充，即用该时间截点的同一行业因子均值进行填充。其次，对异常因子数值采取缩尾处理，对于每一个时间截点，计算每一个因子的均值与标准差，对于偏离均值超过四个标准差的数值采取缩尾，从而剔除极端值的影响。随后，对因子数据进行标准化以统一量纲，将其数值缩放至 $[0, 1]$ 的范围内。

最后，对因子进行中性化处理。部分因子在市值存在相关性，例如市盈率、市净率等，最终导致选股结果集中分布于每一特定市值区间。此外，部分因子在不同行业的分布不同，例如银行业的市盈率相比其他行业普遍偏低，最终导致选股结果集中在特定行业。因此，需要对因子数据进行市值中性化处理和行业中性化处理，降低市值与行业对因子分布的影响。

$$\text{factor}_{i,t} = \beta_{0,t} \log(\text{MarketValue}_{i,t}) + \sum_{j=1}^n \beta_{j,t} \text{Ind}_{j,i,t} + \varepsilon_{i,t} \quad (3.1)$$

其中，对每一个时间截点的每一个因子都对市值和行业哑变量进行回归，每次取回归后的残差代替原始因子，如上式所示。其中 $\text{MarketValue}_{i,t}$ 代表股票 i 在 t 时刻的总市值； $\text{Ind}_{j,i}$ 代表行业虚拟变量，如果股票 i 在 t 时刻属于 j 行业，那么为 1 反之为 0； $\varepsilon_{i,t}$ 为回归残差，作为中性化处理后的结果。图 3.4 展示了 SP

（市销率倒数）与 BP（市净率倒数）两个因子处理器前与处理后的分布。




图 3.4 未处理的因子（左）中性化后的因子（中）标准化后的因子（右）

从因子模型的理论基础 APT 模型推导过程考虑，因子之间应当具有较强的独立性，因子之间强相关关系会导致模型可解释能力变差，也会影响模型的稳定性与最终结果。对因子进行筛选与预处理是后续构建因子模型的前提。由上图相关系数矩阵可知，经过处理后的因子数据，除了技术面维度的动量因子之外，绝大多数因子之间相关性较弱，因子之间几乎不存在明显的共线性。




图 3.5 相关系数矩阵

三、单个因子效果检验

在构建多因子模型之前，先对每一个因子进行检验，如果其单个因子预测效果较差，在后续建模中不加入该因子。参考 Jegadeesh 和 Titman 的研究方法 (Grinblatt 等.,1995)，对于因子每一个大小进行排序并且分为 2 组，跟踪每一组后续的收益率，如果因子两组收益没有明显区别则代表该因子效果不明显。图 3.6 中三幅子图分别代表按照因子排序前 50%、后 50%以及两组相减进行多空对冲后的净值曲线。从多空对冲的结果来看，所有因子净值均保持较好的单调性，即所有因子都能比较有效地预测股票未来收益。




图 3.6 单因子分层测试有效性

第三节 联邦学习模拟多方参与因子模型

本节基于前一节因子数据，使用开源联邦学习框架对多方参与的因子模型训练进行实验模拟。本节对实验设计与测试流程进行详细论述。

一、实验设计

(1) 构建实验数据集。本文在前一节得到的因子数据集特征空间中，随机抽取若干个特征形成若干个数据集，用以模拟多个参与方参与因子模型训练。具体而言，本文对于从因子数据集的 28 个特征中随机抽取 10 个特征，共计得到 5 个子因子数据集，代表 5 个参与方参与因子模型训练，各方都拥有 10 个因子特征。在实际情况下，各方无法获知其他参与者的特征，因此各方的特征空间可能

存在一定的重叠。

表 3.3 实验描述

联邦学习框架	FATE standalone
联邦学习类别	纵向联邦学习
模拟参与方数量	5 个
各方拥有的因子数量	10 个
算法	线性回归、神经网络回归、Secureboost 回归
实验次数	20 次

（2）基于开源联邦学习框架训练因子模型。目前，谷歌、OpenMine、微众银行、百度等企业分别开发并开源了其联邦学习框架 TensorFlow-Federated、PySyft、FATE、PaddleFL(Li 等.,2021)，其中微众银行开发的开源联邦学习框架 FATE 具有一定的优势，其在算法实现层面最丰富，提供了更多的算法选择，因此本文选择使用 FATE 框架进行模拟多方合作的联邦学习因子模型。FATE 框架（Federated AI Technology Enabler）是微众银行与 2019 开发的首个工业级联邦学习框架，FATE 框架覆盖了联邦学习相关的技术场景，包括横向联邦学习、纵向联邦学习、迁移联邦学习以及模型的异步聚合与同步聚合。相比其他开源联邦学习框架，FATE 框架在算法层面最全面，在横向、纵向、迁移联邦学习场景中，该框架实现了各种线性模型、神经网络类以及树模型，其中，除 FATE 框架实现的安全梯度提升树 Secureboost 外，其他开源框架均未实现树模型(林伟伟等.,2023)。

选取三种 FATE 框架提供的算法线性回归、神经网络回归、Secureboost 回归，基于多方的因子数据预测每一只股票下一期的收益率。给其中一个参与方的因子数据训练集加入标签，即下一期的收益率，指定其作为纵向联邦的活跃方（active party），其余参与方为被动方（passive party）进行纵向联邦训练。

（3）预测收益率。完成训练后，各个参与方基于下一期的因子数据通过各自本地模型协同推理，最终得到下一期的预测收益率。

（4）构建选股策略。将股票按照预测收益率排序，从高到低分为等数量的 5 组，构建 5 个等权重投资组合，即每一个组合内股票权重相同。买入预期收益最高的投资组合，卖空预期收入最低的投资组合，构建多空对冲选股策略，通过多空组合减少市场波动的风险。



图 3.7 构建多空对冲组合

二、测试流程

(1) 各参与方提取特征与标签。各个参与方以过去 15 个月的历史因子数据作为原始特征，在每个时间截点上提取下个月的数据作为样本标签，各方对数据进行预处理，包括中性化与标准化，为后续流程提供训练数据。

(2) 滚动联邦学习训练。采取滚动训练方法，各方在联邦学习环境中，对模型进行窗口长度为 15 个月的滚动训练。

(3) 联邦学习样本外预测。各方基于滚动训练的结果，在每月月底基于各方的因子数值进行纵向联邦学习的协同推理，最终得到每一只股票下一期预测收益率。




图 3.8 滚动回归示意图

(4) 各方本地数据单独训练并样本外预测。各方不参与联邦学习训练，根据自身有限特征的因子数据在本地同样进行滚动训练，并预测下一期收益率。

(5) 分别构建投资组合。依据联邦模型和各方本地模型预测的结果，在下期期初构建多空对冲投资组合，买入预期收益最高的投资组合，卖空预期收入最低的投资组合。

(6) 比较单独训练与联邦训练性能。分别从模型判断涨跌能力、投资组合绩效维度出发，比较联邦模型与本地单独训练模型的性能差异。

模型判断涨跌能力。模型判断涨跌是一个二分类任务，因此本文选取受测者

操作特征曲线（Receiver Operating Characteristic Curve, ROC 曲线）所围成的面积，即 AUC 值（Area Under Curve, AUC）测量模型分类性能，衡量模型判断涨跌的能力。ROC 曲线是一条真阳性率（True Positive Rate, TPR）与假阳性率（False Positive Rate, FPR）围成关于阈值的参数方程，计算每一个阈值对应的真阳性率与假阳性率，从而计算出 ROC 曲线的每一个坐标，从而得到 ROC 曲线。AUC 是 ROC 曲线下的面积，AUC 值一般介于 0.5 与 1 之间，越接近 1 则代表该分类器分类能力越强。

投资组合绩效维度。本文将本地训练模型与联邦训练模型的投资组合绩效进行评估，本文首先对累计收益率进行比较，此外也要考虑投资组合的风险水平，其中包括组合波动性、最大回撤、夏普比率与卡玛比率。

累计收益率：投资组合在一段时间内月收益率之和。

波动率：投资组合一段时间内收益率的标准差

最大回撤：最大回撤是指投资组合净值最高点到最后最低点回撤幅度的最大值，在新的峰值之前，峰顶到谷底观察到的组大亏损，其反应了策略可能发送的最大亏损幅度。最大回撤是衡量组合的风险控制能力最常用的指标。

夏普比率：夏普比率是组合收益与波动率的比值，反应了每承担一定数量的风险，带来的收益量。其中 $E(r)$ 为组合的期望收益， r_f 为无风险收益率， σ 为收益率的波动率。

$$SP = \frac{E(r) - r_f}{\sigma} \quad (3.2)$$

卡玛比率：夏普比率是组合收益与最大回撤的比值，反应了每承担一定数量的回撤风险，带来的收益量。其中 $E(r)$ 为组合的期望收益， r_f 为无风险收益率， md 为组合的最大回撤。

$$CR = \frac{E(r) - r_f}{md} \quad (3.3)$$

第四节 联邦学习因子模型效果评估

本文按照其一节的测试流程进行实验测试，由于随机送因子池抽取因子模拟参与方的因子数据存在一定的偶然性，本文重复上述实验 20 次，每次模拟 5 个参与方进行联邦学习训练，最终收集到 100 个参与方的预测结果，以下各方本

地训练模型和联邦训练模型的指标均作平均处理。

一、模型判断涨跌能力

经过上述滚动回归并预测，得到每一期期末各参与方对每一只股票的预测收益率，包括联邦模型以及各方本地训练模型，若预测收益率大于 0，则模型预测该股票未来上涨，反之则下跌，因此，本文选择 AUC 指标评估该二分类任务。图跟踪了 2016 年 3 月至 2023 年 3 月共计 85 期的各方本地训练与联邦学习模型的 AUC 值，由图可知，树模型、线性模型以及神经网络模型本地单独训练的性能都不及联邦训练，从因子模型的实际场景考虑，参与方自身本地训练仅利用到了自身有限数量的因子，因此对收益率的解释力度不及联邦学习模型，实验结果与常理相符。




图 3.9 本地训练与联邦学习 AUC 值差异

二、组合绩效评估

基于上述模型预测结果构建投资组合，图 3.10 是分层进行回测的结果，从组合 1 至组合 5 代表分别按照模型预测收益率升序排列的股票组合，其中每一个分层组合内股票权重相等。在回测过程中，在每一个自然月份的最后一日计算因子数值，并基于该因子通过模型预测股票收益率，随后在下一个自然月的首个交易日调仓，买入预期收益最高的投资组合，卖空预期收入最低的投资组合，得到多空对冲组合。图 3.10 是其中一次联邦神经网络模型的投资组合收益率情况，按照预测收益率由低到高排序，并构建组合 1 至组合 5，由图可知，分层组合在测试期间的真实收益也符合由低到高，排序自始至终保持了较好的单调性，预测收益率高的组合显著超过预测收益率低的组合，表明该策略的有效性。同时，该

策略也大幅超过市场平均表现，该策略取得 190%的收益率，而同期沪深 300 涨幅为 40.78%，通过因子模型进行构建策略可以大幅跑赢市场平均表现。




图 3.10 联邦学习神经网络模型 组合收益率

表 3.4 联邦训练与本地训练模型投资组合回测对比

			多空对冲组合
平均累计收益率	神经网络	本地训练	113.41%
		联邦训练	189.64%
	线性模型	本地训练	93.46%
		联邦训练	147.86%
	树模型	本地训练	62.09%
		联邦训练	159.47%
平均最大回撤	神经网络	本地训练	27.21%
		联邦训练	38.30%
	线性模型	本地训练	23.78%
		联邦训练	22.35%
	树模型	本地训练	16.78%
		联邦训练	

平均夏普比率	神经网络	联邦训练	31.37%
		本地训练	1.1389
		联邦训练	1.1505
	线性模型	本地训练	1.0978
		联邦训练	1.2198
		本地训练	1.1456
平均卡玛比率	树模型	联邦训练	1.2479
		本地训练	4.1231
		联邦训练	4.9511
	神经网络	本地训练	4.3613
		联邦训练	6.2174
		本地训练	3.7418
	树模型	本地训练	5.0825
		联邦训练	

表 3.4 对比了各方基于本地数据训练与联邦训练构建策略的组合绩效。可以看出，在神经网络、线性模型以及树模型下，联邦学习联合训练因子累计收益率均高于于本地单独训练模型；从最大回撤角度看，神经网络与树模型联邦训练虽然不及各方单独训练，但是考虑到前者有更高的累计收益率，因而更有可能承担更大回撤的风险；夏普比率与卡玛比率指标能够综合衡量组合的风险与回报，组合分别代表每承担一单位的波动风险（回撤风险）获取的回报，由表中信息可知，联邦训练的平均夏普比率与平均卡玛比率全部超过本地训练模型。综上所述，从投资组合绩效维度来看，联邦训练的投资组合平均优于本地训练。

第五节 本章小节

首先，本章具体论述多方合作的因子模型背景，首先从二者的应用场景出发，论述二者结合运用的合理性，随后基于纵向联邦学习技术原理与因子模型训练需求，从技术原理论述将纵向联邦学习技术应用至多方合作因子模型的可行性。

其次，本章构建了一套多方合作的因子模型联邦训练流程，并在基于开源联邦学习框架 FATE 进行实验模拟，构建 2014 年-2023 年因子数据集进行构建投资组合。同时，还模拟了各方本币单独训练的结果作为参考标准，对比各方单独训

练与联邦训练的差异。结果表明，联邦学习均能有效提升各方模型的效果，平均而言联邦训练的模型性能优于各方单独训练，此外，基于模型预测结果构建的投资组合上，前者投资组合的绩效也更优秀。

综上所述，因子投资模型在联邦学习场景中的应用，在应用场景与技术原理层面均具有合理性，并且实验表明各方均能通过联邦学习获取收益。

第四章 基于演化博弈联邦学习因子模型可行性分析

第一节 博弈主体及其行为分析

虽然第三章通过理论分析与实验模拟因子投资模型在联邦学习场景中的应用,论证了二者在应用场景与技术原理层面结合运用具有合理性,各方均能通过联邦学习获取收益。然而,多方通过联邦学习参与因子模型的实践涉及诸多隐性机制,其中各个利益相关方之间复杂的利益关联机制是其中最重要的一环,没有公平的利益机制对各方行为进行约束与奖惩,各方不会有动机持续参与其中。为了分析上述问题,本章通过首先甄别体系中的利益相关者及其角色,梳理他们之间的利益机制,分析其利益目标、行为选择以及博弈关系,意图再现背后的利益交叉网络,并据此研究影响各方博弈结果的影响因素。

一、联邦学习因子模型合作机制的利益相关者

利益相关研究的关键在于界定利益相关者,如果无法确定利益相关者,那么探讨各个利益相关方对企业的协同治理就无从谈起(贾生华,陈宏辉,2002)。联邦学习因子模型合作中的利益相关者有政府部门、联邦平台(联邦组织者)、联邦参与方(数据提供方与模型使用方)。

(1) 政府部门。随着国家对数据要素加强监管,数据所有方的数据安全性与可得性产生一定的冲突,联邦学习技术能够兼顾数据安全性与数据可用性,其实践应用将会对全社会潜在的数据流通项目产生示范效应,具有极强的正外部性,带动社会基于联邦学习等隐私计算技术打破数据孤岛,让数据通过联邦学习在流通产生价值。

(2) 联邦平台(联邦组织者)。以全局模型为中心的合作模式是联邦学习一种常见的合作模式,即各参与方仅负责计算本地的局部模型,将计算的局部模型参数上传到专门的参数服务器。在因子模型的背景下,各方存在一定的竞争关系,各方均为潜在的竞争对手,如果某一参与方作为模型聚合者,那么其有可能获知各方局部模型的细节。因此,联邦学习因子模型需要引入第三方联邦平台,而不是让某一参与方负责模型聚合。联邦平台可视为联邦组织者,各方基于平台的框架参与联邦学习,联邦学习平台对各个参与方负有监管责任,并确保各方的利

益以及体系的公平性。

(3) 联邦参与方(数据提供方与模型使用方)。在联邦学习中,联邦学习的参与方可以分解为两个角色——数据提供方与模型使用方,各方既是数据提供方也是联邦模型使用方,各参与方在联邦学习执行过程中,通过联邦学习提供自身数据后,对全局模型进行动态评估,判断联邦模型是否比本地模型优秀,若联邦模型不及本地模型,那么参与方将不会选择使用联邦模型。

由于联邦学习因子模型的数据为各方私有因子数据,理论上市场化程度较高,而联邦学习实践应用示范效应带给政府的正外部性,对其余利益相关方影响较少且难以量化,因此出于简化模型考量,将博弈主体简化为联邦平台、数据提供方与模型使用方。

二、联邦平台、模型使用方、数据提供方三方关系

联邦平台作为整个体系的基石,承担联邦发起与组织的任务,平台负责为联邦参与方(数据提供方与模型使用方)提供基础服务,促使各方参与联邦模型训练,鼓励数据提供方使用优质数据参与联邦。与此同时,平台也需要付出一定的监管成本,规范数据提供方与模型使用方的行为,鼓励模型使用方、数据提供方的正面行为,惩罚负面行为。

数据提供方是指联邦学习参与方提供数据参与联邦这一角色,参与方基于联邦平台通过提供数据获取一定的收益,并且数据质量受到联邦平台的监管。

模型使用方是指联邦学习参与方使用联邦模型这一角色,模型使用方通过联邦平台向数据提供方支付一定比例报酬,并综合考虑联邦模型的收益与成本选择是否采用联邦模型。

三、利益相关者的行为分析

(1) 联邦平台行为分析

联邦学习平台作为多方合作的组织者、发起者以及管理者,通过联邦学习技术使得各方因子数据流通,确保数据在数据提供方与模型使用方之间流转,多方共同创造价值。联邦学习需要拥有优质计算资源与高质量数据的联邦参与方,而平台只有保证安全性与公平性,才能吸引高质量的联邦参与方(数据提供方与模型使用方)。联邦平台的策略包括积极管理或消极管理。

在数据安全性层面,纵向联邦学习技术作为一种隐私计算方法,能够从技术

上避免可能的因子数据信息泄露，保障因子数据的安全性。

在数据安全性层面，联邦平台需要对各方行为进行监管与规范，设置一定的奖惩制度，保证优质参与方的利益。其中包括因子数据质量监管、模型规范使用监管。然而，联邦平台监管也存在一定的经济制约。首先，联邦平台的监管会造成平台运营成本增加。此外，平台的主要收入来自于模型使用方的收益抽成，因此平台希望更多个体参与联邦获得更多抽成，从而选择降低监管门槛，这会导致大量良莠不齐的数据参与联邦学习，损害各方利益导致平台形象恶化。联邦平台消极监管短期内会增加平台收入，但长期消极监管将导致大量劣质数据参与联邦训练，最终系统整体难以为继。

（2）数据提供方行为分析

数据提供方通过联邦平台参与联邦学习训练并获取收益，其提供的数据质量决定了最终联邦模型的性能，若数据提供方使用优质因子数据参与训练，则受到平台额外奖励，若其恶意使用劣质数据，则受到平台处罚。

（3）模型使用方行为分析

模型使用方基于其使用联邦模型的收益，向数据提供方支付佣金，模型使用方自身会对联邦模型进行评估，其综合考量联邦模型的成本与收益后，决定采用联邦模型，或者弃用联邦模型从而采用死神单独训练模型。

第二节 演化博弈模型构建

一、研究假设与参数说明

为了开展多方参与联邦因子模型演化博弈研究，在描述联邦平台、数据提供方与模型使用方主体的演化博弈过程中，对模型作出必要的假设，根据三个博弈主体的行为策略与前提假设，将博弈过程的参数汇总如表 4.1。

假设 1 有限理性假设：由于联邦平台、数据提供方与模型使用方博弈主体的认知有限且难以获取完全信息，三方主体并非完全理性，本文假定联邦平台、数据提供方与模型使用方基于均为有限理性，基于最大化自身利益的原则，在动态地重复博弈中确定自身最优策略。

平台以最大化自身利益为决策目标，综合考量平台抽成收益、平台形象以及监管成本，选择“积极管理”或“消极管理”作为博弈策略，“积极管理”将会使平台付出 C_p 的监管成本；数据提供方最大化自身利益，选择提供“优质因子

数据”或“劣质因子数据”，提供“优质因子数据”成本为 C_g ，假定其提供“劣质因子数据”的收益 R_b 大于提供“优质因子数据”的收益 R_g ；最后，模型使用方也会根据采用联邦模型成本与收益，选择“采用模型”或者“弃用模型”。联邦平台选择“积极管理”和“消极管理”的概率分别为 z 与 $1-z$ ，数据提供方提供“优质因子数据”和“劣质因子数据”的概率分别为 y 与 $1-y$ ，模型使用方“采用模型”和“弃用模型”的概率分别为 x 与 $1-x$ 。

假设 2 假设平台对模型使用方收益抽成比例为 α ，对于模型使用方，在不考虑因子数据质量的情况下，假定采用联邦模型参与联邦训练会导致额外的成本开支，因此模型使用方不会选择采用联邦模型，即 $R_{dep} > R_{use}$ 。只有当优质因子数据的额外收益弥补成本开支时，才会选择采用联邦模型。

假设 3 平台为了鼓励数据提供方提供优质数据，对优质数据提供方奖励 A_g ，对劣质因子提供方处罚 P_b 。此外，平台为了鼓励各方参与联邦，假定其在其积极管理时对采用联邦模型提供 A_{use} 的奖励，且该奖励足以覆盖模型使用方采用联邦模型的额外成本，即 $A_{use} > (1-\alpha)(R_{dep} - R_{use})$ 。

假设 4 假定各方参与联邦会影响即形象，对于联邦平台采取积极监管策略，将会带来 F 的平台形象提升；对于数据提供方，提供优质数据会带来正面形象 F_{pp} ，反之则带来 F_{pm} 的负面形象；对于模型使用方，假定采用模型的正面示范效应 K ，弃用模型的负面示范效应 L 。

表 4.1 参数符号及其含义

参数	参数名	含义
R_{use}	采用联邦模型效用	模型使用方使用联邦模型的效用
R_{dep}	弃用联邦模型效用	模型使用方弃用联邦模型的效用
C_g	提供优质因子成本	数据提供方提供优质因子数据成本
R_g	提供优质因子收益	数据提供方提供优质因子数据的收益
R_b	提供劣质因子收益	数据提供方提供劣质因子数据的收益
V_g	采用优质联邦模型额外收益	数据提供方提供优质因子数据时，模型使用方采用联邦模型的额外收益
V_b	弃用优质联邦模型额外损失	数据提供方提供优质因子数据时，模型使用方弃用联邦模型的利益损失
F_{pp}	参与方形象增加	参与方提供优质因子数据，带来增强正面形象
F_{pm}	参与方形象恶化	参与方提供劣质因子数据，带来形象降低
C_p	平台管理成本	联邦平台采取积极监管策略导致的运营成本增加
F	平台形象提升	联邦平台采取积极监管策略增强平台正面形象
P_b	提供劣质因子的惩罚	联邦平台采取积极监管策略时，惩罚提供劣质因子的提供方
A_g	提供优质因子的奖励	联邦平台采取积极监管策略时，奖励提供优质因子的提供方
A_{use}	采用联邦模型额外奖励	联邦平台采取积极监管策略时，鼓励采用模型的行为
K	采用模型的正面示范效应	模型使用方采用模型的正面示范效应
L	弃用模型的负面示范效应	模型使用方弃用模型的负面示范效应
α	分成比例	模型使用方向数据提供方支付的报酬比例

表 4.2 “联邦平台-数据提供方-模型使用方”三方博弈支付矩阵

联邦平台	数据提供方	模型使用方	
		采用联邦模型 x	弃用联邦模型 $1 - x$
积极管理	提供优质因子 y	$\begin{pmatrix} (1-\alpha)R_{use} + V_g + A_{use} \\ R_g + \alpha R_{use} - C_g + F_{pp} + A_g - V_g \\ K + F - C_p - A_{use} - A_g \end{pmatrix}$	$\begin{pmatrix} (1-\alpha)R_{dep} - V_b \\ R_g + \alpha R_{dep} - C_g + F_{pp} + A_g \\ F - L - C_p - A_g \end{pmatrix}$
	提供劣质因子 $1 - y$	$\begin{pmatrix} (1-\alpha)R_{use} + A_{use} \\ R_b + \alpha R_{use} - F_{pm} - P_b \\ K + F - C_p - A_{use} \end{pmatrix}$	$\begin{pmatrix} (1-\alpha)R_{dep} \\ R_b + \alpha R_{dep} - F_{pm} - P_b \\ F - L - C_p \end{pmatrix}$
消极管理	提供优质因子 y	$\begin{pmatrix} (1-\alpha)R_{use} + V_g \\ R_g + \alpha R_{use} - C_g + F_{pp} - V_g \\ K \end{pmatrix}$	$\begin{pmatrix} (1-\alpha)R_{dep} - V_b \\ R_g + \alpha R_{dep} - C_g + F_{pp} \\ -L \end{pmatrix}$
	提供劣质因子 $1 - y$	$\begin{pmatrix} (1-\alpha)R_{use} \\ R_b + \alpha R_{use} - F_{pm} \\ K \end{pmatrix}$	$\begin{pmatrix} (1-\alpha)R_{dep} \\ R_b + \alpha R_{dep} - F_{pm} \\ -L \end{pmatrix}$

二、复制动态方程建立

由“联邦平台-数据提供方-模型使用方”三方博弈策略选择及其收益可得，模型使用方“采用联邦模型”与“弃用联邦模型”的期望收益 P_x 、 P_{1-x} 以及平均收益 $\bar{P}$ 分别为：

$$\begin{aligned}
P_x &= yz[(1-\alpha)R_{use} + V_g + A_{use}] + (1-y)z[(1-\alpha)R_{use} + A_{use}] \\
&\quad + y(1-z)[(1-\alpha)R_{use} + V_g] + (1-y)(1-z)(1 \\
&\quad - \alpha)R_{use} \\
P_{1-x} &= yz[(1-\alpha)R_{dep} - V_b] + (1-y)z(1-\alpha)R_{dep} + y(1-z)[(1 \\
&\quad - \alpha)R_{dep} - V_b] + (1-y)(1-z)(1-\alpha)R_{dep} \\
\bar{P} &= xP_x + (1-x)P_{1-x}
\end{aligned} \tag{4.1}$$

同理可得，数据提供方“提供优质因子数据”与“提供劣质因子数据”的期望收益 B_y 、 B_{1-y} 以及平均收益 $\bar{B}$ 分别为：

$$\begin{aligned}
B_y &= xz(R_g + \alpha R_{use} - C_g + F_{pp} + A_g - V_g) + (1-x)z(R_g \\
&\quad + \alpha R_{dep} - C_g + F_{pp} + A_g) + x(1-z)(R_g + \alpha R_{use} \\
&\quad - C_g + F_{pp} - V_g) + (1-x)(1-z)(R_g + \alpha R_{dep} - C_g \\
&\quad + F_{pp}) \\
B_{1-y} &= xz(R_b + \alpha R_{use} - F_{pm} - P_b) + (1-x)z(R_b + \alpha R_{dep} \\
&\quad - F_{pm} - P_b) + x(1-z)(R_b + \alpha R_{use} - F_{pm}) + (1-x)(1 \\
&\quad - z)(R_b + \alpha R_{dep} - F_{pm}) \\
\bar{B} &= yB_y + (1-y)B_{1-y}
\end{aligned} \tag{4.2}$$

同理可得，联邦平台“积极管理”与“消极管理”的期望收益 U_z 、 U_{1-z} 以及平均收益 $\bar{U}$ 分别为：

$$\begin{aligned}
U_z &= xy(K + F - C_p - A_{use} - A_g) + x(1-y)(K + F - C_p - A_{use}) \\
&\quad + (1-x)y(F - L - C_p - A_g) + (1-x)(1-y)(F - L \\
&\quad - C_p) \\
U_{1-z} &= xyK + x(1-y)K + (1-x)y(-L) + (1-x)(1-y)(-L) \\
\bar{U} &= zU_z + (1-z)U_{1-z}
\end{aligned} \tag{4.3}$$

根据演化博弈理论，可以建立联邦平台-数据提供方-模型使用方”三方动态复制方程(程乐峰等.,2021)，并联立为三维动力系统微分方程组M。

$$\begin{cases} P(x) = \frac{dx}{dt} = x(P_x - \bar{P}) = x(1-x)[(1-\alpha)(R_{use} - R_{dep}) + y(V_g + V_b) + zA_{use}] \\ B(y) = \frac{dy}{dt} = y(B_y - \bar{B}) = y(1-y)[R_g - R_b - C_g + F_{pp} + F_{pm} - xV_g + z(P_b + A_g)] \\ U(z) = \frac{dz}{dt} = z(U_z - \bar{U}) = z(1-z)(F - C_p - xA_{use} - yA_g) \end{cases} \quad (4.4)$$

第三节 系统均衡点以及稳定性分析

命题 1 动力系统 M 的存在 9 个局部均衡点 $E_1(0,0,0)$ 、 $E_2(0,0,1)$ 、 $E_3(0,1,0)$ 、 $E_4(0,1,1)$ 、 $E_5(1,0,0)$ 、 $E_6(1,0,1)$ 、 $E_7(1,1,0)$ 、 $E_8(1,1,1)$ 、 $E_9(x^*, y^*, z^*)$ 。

证明 动力系统的均衡状态满足 $F(x) = 0$ ，令 $P(x) = B(y) = U(z) = 0$ ，显然可得 $E_1(0,0,0)$ 、 $E_2(0,0,1)$ 、 $E_3(0,1,0)$ 、 $E_4(0,1,1)$ 、 $E_5(1,0,0)$ 、 $E_6(1,0,1)$ 、 $E_7(1,1,0)$ 、 $E_8(1,1,1)$ 为均衡点，联立方程可得 $E_9(x^*, y^*, z^*)$ ，其中 $P(x^*) = B(y^*) = U(z^*) = 0$ 。

命题 2 动力系统 M 存在 $E_1(0,0,0)$ 、 $E_6(1,0,1)$ 、 $E_7(1,1,0)$ 、 $E_8(1,1,1)$ 共计 4 个演化稳定策略。

证明 在非对称博弈模型中，混合均衡策略一定不是演化稳定均衡，多种群的演化稳定解必是严格纳什均衡解即纯策略均衡解，故只需对 E_1 至 E_8 纯策略均衡点进行稳定性分析(Selten, Selten, 1988)。为验证均衡策略的稳定性，首先求解该系统的雅各比矩阵。

$$\begin{aligned} J &= \begin{bmatrix} \frac{\partial P(x)}{\partial x} & \frac{\partial P(x)}{\partial y} & \frac{\partial P(x)}{\partial z} \\ \frac{\partial B(x)}{\partial x} & \frac{\partial B(x)}{\partial y} & \frac{\partial B(x)}{\partial z} \\ \frac{\partial U(x)}{\partial x} & \frac{\partial U(x)}{\partial y} & \frac{\partial U(x)}{\partial z} \end{bmatrix} \\ &= \begin{bmatrix} Q_1 & x(1-x)(V_g + V_b) & x(1-x)A_{use} \\ -y(1-y)V_g & Q_2 & y(1-y)(P_b + A_g) \\ -z(1-z)A_{use} & -z(1-z)A_g & Q_3 \end{bmatrix} \end{aligned} \quad (4.5)$$

其中 $Q_1 = (1-2x)[(1-\alpha)(R_{use} - R_{dep}) + y(V_g + V_b) + zA_{use}]$,

$$Q_2 = (1 - 2y)[R_g - R_b - C_g + F_{pp} + F_{pm} - xV_g + z(P_b + A_g)] ,$$

$$Q_3 = (1 - 2z)(F - C_p - xA_{use} - yA_g)$$

由 Lyapunov 判别法可知, 对于一个复制动态系统, 若该系统某个均衡点雅各比矩阵全部特征值满足 $\lambda_i < 0$, 则该均衡点为渐进稳定点, 也称汇; 若全部特征值满足 $\lambda_i > 0$, 则称为源, 为非稳定均衡; 某个均衡点雅各比矩阵全部特征值既有正也有负, 则该均衡点为鞍点(胡春华等.,2023)。其中, $E_2(0,0,1)$ 、 $E_3(0,1,0)$ 、 $E_4(0,1,1)$ 、 $E_5(1,0,0)$ 不满足全部特征小于零, 因此为不稳定状态。 $E_1(0,0,0)$ 、 $E_6(1,0,1)$ 、 $E_7(1,1,0)$ 、 $E_8(1,1,1)$ 在特定条件下为演化稳定策略。

$E_1(0,0,0)$: 当 $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm} < 0$, 且 $\lambda_3 = F - C_p < 0$ 时, 该点为渐进稳定状态, 其余情况为不稳定的鞍点, 此时模型使用方、数据提供方和联邦平台最终分别选择“弃用联邦模型”、“提供劣质因子数据”和“平台消极管理”。

$E_6(1,0,1)$: 当 $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g < 0$, 且 $\lambda_3 = -(F - C_p - A_{use}) < 0$ 时, 该点为渐进稳定状态, 其余情况为不稳定的鞍点, 此时模型使用方、数据提供方和联邦平台最终分别选择“采用联邦模型”、“提供劣质因子数据”和“平台积极管理”。

$E_7(1,1,0)$: 当 $\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm} - V_g) < 0$, 且 $\lambda_3 = F - C_p - A_{use} - A_g < 0$ 时, 该点为渐进稳定状态, 其余情况为不稳定的鞍点, 此时模型使用方、数据提供方和联邦平台最终分别选择“采用联邦模型”、“提供优质因子数据”和“平台消极管理”。

$E_8(1,1,1)$: 当 $\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g) < 0$, 且 $\lambda_3 = -(F - C_p - A_{use} - A_g) < 0$ 时, 该点为渐进稳定状态, 其余情况为不稳定的鞍点, 此时模型使用方、数据提供方和联邦平台最终分别选择“采用联邦模型”、“提供优质因子数据”和“平台积极管理”。

表 4.3 均衡点特征值及其稳定性分析

均衡点	特征值	稳定性
$E_1(0,0,0)$	$\lambda_1 = (1 - \alpha)(R_{use} - R_{dep});$ $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm};$ $\lambda_3 = F - C_p$	渐进稳定状态
$E_2(0,0,1)$	$\lambda_1 = (1 - \alpha)(R_{use} - R_{dep}) + A_{use} > 0;$ $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm} + P_b + A_g;$ $\lambda_3 = F - C_p;$	不稳定状态
$E_3(0,1,0)$	$\lambda_1 = (1 - \alpha)(R_{use} - R_{dep}) + V_g + V_b > 0;$ $\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm});$ $\lambda_3 = F - C_p - A_g;$	不稳定状态
$E_4(0,1,1)$	$\lambda_1 = (1 - \alpha)(R_{use} - R_{dep}) + V_g + V_b + A_{use} > 0;$ $\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm} + P_b + A_g);$ $\lambda_3 = -(F - C_p - A_g);$	不稳定状态
$E_5(1,0,0)$	$\lambda_1 = -(1 - \alpha)(R_{use} - R_{dep}) > 0;$ $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm} - V_g;$ $\lambda_3 = F - C_p - A_{use};$	不稳定状态
$E_6(1,0,1)$	$\lambda_1 = -((1 - \alpha)(R_{use} - R_{dep}) + A_{use});$ $\lambda_2 = R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g;$	渐进稳定状态

	$\lambda_3 = -(F - C_p - A_{use});$	
	$\lambda_1 = -((1 - \alpha)(R_{use} - R_{dep}) + V_g + V_b);$	
$E_7(1,1,0)$	$\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm} - V_g);$	渐进稳定状态
	$\lambda_3 = F - C_p - A_{use} - A_g;$	
	$\lambda_1 = -((1 - \alpha)(R_{use} - R_{dep}) + V_g + V_b + A_{use});$	
$E_8(1,1,1)$	$\lambda_2 = -(R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g);$	渐进稳定状态
	$\lambda_3 = -(F - C_p - A_{use} - A_g);$	

第四节 算例分析

本节按照上一节分析，对出于渐进稳定状态的均衡点进行算例仿真分析，分析“联邦平台-数据提供方-模型使用方”三方博弈演化过程。本文选取多方合作的联邦因子模型其中3个具有代表性的阶段，①发展初期阶段： $E_1(0,0,0)$ ，②过渡阶段： $E_6(1,0,1)$ 、 $E_7(1,1,0)$ ，③模式成熟阶段 $E_8(1,1,1)$ 。

一、发展初期阶段

模式发展初期阶段 $E_1(0,0,0)$ ，各项条件均不成熟，各方采取最消极的态度均不愿参与联邦。根据前文均衡点稳定性计算结果，模型稳于 $E_1(0,0,0)$ 达到稳定状态，需同时满足 $R_g - C_g + F_{pp} < R_b - F_{pm}$ 和 $F < C_p$ ，基于此给参数赋值 $R_{use} = 80, R_{dep} = 160, R_g = 120, R_b = 90, V_g = 50, A_{use} = 50, A_g = 20, V_b = 80, P_b = 40, F_{pp} = 20, F_{pm} = 20, C_g = 80, F = 50, C_p = 100, \alpha = 0.1$ ，从随机策略出发模拟200次演化路径如图4.1所示。此外，图4.2展示了该参数对应的概率随时间演化的过程，初始策略分别为(0.3, 0.3, 0.3)与(0.7, 0.7, 0.7)，初始概率为0.7时，数据提供方有较大概率提供优质因子数据，联邦平台也有较高概率积极管理，鼓励采用联邦模型，因此模型

使用方采用联邦模型的概率快速提升。随着演化推进，提供优质因子数据与积极管理的概率下降，模型使用方采用联邦模型的医院快速下降，直至收敛至 0。而初始概率为 $(0.3, 0.3, 0.3)$ 时，各方均没有足够的激励，导致三方概率快速收敛至 0。模式发展初期阶段，平台缺乏相关管理经验、管理水平较低，平台处于被动的消极管理状态；对数据提供方，面对一个刚起步的联邦平台，数据提供方一开始很难信任该平台，而平台消极管理也无法给予数据提供方激励；对于模型使用方，其需要将联邦模型与本地模型进行对比，择其善者，而平台消极管理，加之数据提供方没有优质因子进行联邦学习训练，模型使用方必然会弃用联邦模型。在没有外力干涉的情况下，最终形成三方皆输的局面。




图 4.1 发展初期阶段 $E_1(0,0,0)$ 三维演化路径




图 4.2 发展初期阶段 $E_1(0,0,0)$ 的演化稳定性

二、过渡阶段

随着各项条件逐渐趋向成熟，特别是联邦平台的管理水平提升，模式进入过渡阶段，存在两种可能性 $E_6(1,0,1)$ 和 $E_7(1,1,0)$ 。

$E_6(1,0,1)$ 由于虽然联邦平台积极管理，并鼓励各方参与使用联邦模型，但是对提供优质因子的参与方激励不足，导致各方不愿分享自身高质量数据。在联邦因子模型中，高质量的因子数据是模型性能的关键因素，此时没有优质因子参与其中。虽然当前联邦平台积极管理，模型使用方采用联邦模型，但是整体模式无效，模型使用方仅仅为了得到平台的奖励而采用联邦模型，联邦模型不能为参与方带来实际收益。联邦平台需要继续提高管理水平，尤其是对数据提供方的奖惩制度，才能摆脱无效的联邦学习模式。根据前文均衡点稳定性计算结果，模型稳于 $E_6(1,0,1)$ 达到稳定状态，需同时满足 $R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g < 0$ 和 $F > C_p + A_{use}$ ，基于此给参数赋值 $R_{use} = 50, R_{dep} = 150, R_g = 100, R_b = 250, V_g = 50, A_{use} = 150, A_g = 20, V_b = 80, P_b = 40, F_{pp} = 80, F_{pm} = 80, C_g = 80, F = 260, C_p = 100, \alpha = 0.1$ ，三维演化路径如图 4.3 所示。







图 4.3 过渡阶段 $E_6(1,0,1)$ 三维演化路径

图 4.4 过渡阶段 $E_6(1,0,1)$ 的演化稳定性

$E_7(1,1,0)$ 虽然联邦平台消极管理，但是部分高质量因子数据参与联邦，从而激发出各方积极性，模型使用方与数据提供方持续参与形成正向激励，联邦平台无需过多介入，积极管理反而耗费大量资源，降低整体效用。根据前文均衡点稳定性计算结果，模型稳于 $E_6(1,0,1)$ 达到稳定状态，需同时满足 $R_g - R_b - C_g + F_{pp} + F_{pm} - V_g > 0$ 和 $F - C_p < A_{use} + A_g$ ，基于此给参数赋值 $R_{use} = 50, R_{dep} = 150, R_g = 180, R_b = 100, V_g = 40, A_{use} = 20, A_g = 40, V_b = 80, P_b = 80, F_{pp} = 20, F_{pm} = 50, C_g = 100, F = 150, C_p = 100, \alpha = 0.1$ ，三维演化路径如图 4.5 所示。此外，图 4.6 展示了该参数对应的概率随时间演化的过程，初始策略分别为 $(0.3, 0.3, 0.3)$ 与 $(0.7, 0.7, 0.7)$ ，初始概率为 0.3 时，数据提供方能通过联邦获取较高收益，因此其选择提供优质数据，随着提供优质因子数据概率上升，模型使用方也更倾向于使用模型从而最大化利益。此时，不需要联邦平台对各方额外的激励措施，数据提供方与模型使用方就能形成良性互动，造成“强市场，弱监管”的局面。

图 4.5 过渡阶段 $E_7(1,1,0)$ 三维演化路径图 4.6 过渡阶段 $E_7(1,1,0)$ 的演化稳定性

三、成熟阶段

随着机制逐渐成熟稳定，联邦平台、数据提供方和模型使用方达到了相互促进的最优方向，三方在联邦学习模式中良性互动，达到模式最终成熟阶段 $E_8(1,1,1)$ 。根据前文均衡点稳定性计算结果，模型稳于 $E_8(1,1,1)$ 达到稳定状

态,需同时满足 $R_g - R_b - C_g + F_{pp} + F_{pm} - V_g + P_b + A_g > 0$ 和 $F - C_p > A_{use} + A_g$, 基于此条件给参数赋值 $R_{use} = 50, R_{dep} = 150, R_g = 180, R_b = 100, V_g = 40, A_{use} = 20, A_g = 40, V_b = 80, P_b = 80, F_{pp} = 20, F_{pm} = 50, C_g = 100, F = 200, C_p = 100, \alpha = 0.1$ 。此时, 联邦平台管理水平趋近完善, 针对数据提供方的奖惩机制设置比较完善, 联邦因子模型从过渡阶段的双方良性互动, 转向联邦平台、数据提供方和模型使用方三方良性互动。




图 4.7 成熟阶段 $E_8(1,1,1)$ 三维演化路径




图 4.8 成熟阶段 $E_8(1,1,1)$ 的演化稳定性

第五节 演化博弈结果影响因素分析

“联邦平台-数据提供方-模型使用方”三方博弈演化过程，根据演化稳定性结果划分为发展初期阶段、过渡阶段以及成熟阶段，成熟阶段三方“采用联邦模型”、“提供优质因子数据”、“平台积极管理”，三方达到良性互动的最优局面。本节针对成熟阶段 $E_8(1,1,1)$ 进行研究，探讨影响该阶段策略演化的因素。

一、奖惩设计的影响

“联邦平台-数据提供方-模型使用方”三方博弈演化过程中，联邦平台通过奖惩机制引导和规范数据提供方与模型使用方的行为，其中包括对奖励提供优质因子数据、惩罚恶意提供劣质因子数据以及鼓励模型使用方采用联邦模型。联邦平台为了鼓励各方积极参与，鼓励模型使用方采用联邦模型，由图可知，对模型使用方的正向激励有助于其博弈更快收敛。此外，平台对劣质因子的惩罚，会激励数据方提供优质数据，同时也会吸引模型参与方更有可能采用联邦模型。综上所述，平台对各方正面行为激励，对负面行为惩罚都有助于模型博弈加快收敛，达到多方价值共创的理想状态。




图 4.9 平台对模型使用方奖励 A_{use} 对演化系统的影响




图 4.10 平台对优质因子数据奖励 A_g 对演化系统的影响




图 4.11 平台对劣质因子数据惩罚 P_b 对演化系统的影响

二、分成设计的影响

数据提供方对模型使用方抽取一定比例的佣金，从经济逻辑考虑，提高抽佣比例数据提供方将会激励数据提供方提供更优质的数据。但是，过高的分成比例会导致模型使用方不愿意支付过高的代价参与其中。可以看出，抽佣比例也是影响策略演化的重要因素。本文探究不同 α 对演化路径的影响，分别取 $\alpha = 0.1, \alpha = 0.3, \alpha = 0.5$ ，演化路径由图 4.12 所示，提高抽佣比例使得模型使用方更快收敛，在演化初期提高分成比例能够激励数据提供方积极参与联邦，模型使用方得到联邦模型性能快速提升，形成良好的三方协作关系。




图 4.12 不同分成比例 α 对演化系统的影响

第六节 本章小节

多方通过联邦学习参与因子模型的实践存在诸多问题，各个利益相关方之间复杂的利益关联机制是其中最重要的因素。本文首先识别出利益相关者，将其简化为联邦平台、数据提供方以及模型使用方，对三方行为、主体关系以及博弈关系进行梳理，从而进行演化博弈建模。随后，通过演化博弈理论，对演化策略

的稳定性进行分析，得到 4 个可能的演化稳定策略，分别对应多方合作的联邦因子模型的发展初期阶段、过渡阶段以及成熟阶段。最后，分析对影响演化系统的因素进行分析，结果表明良好的分成机制与奖惩机制都有助于模型在博弈早期更快收敛。

第五章 总结和研究展望

首先,本文以因子模型作为理论支撑,基于联邦学习技术构建了一套多方参与的因子选股模型。首先,本文从理论上论证将联邦学习应用于因子模型的合理性,从二者的背景出发,因子公开曝光会导致有效性降低,各方均不愿意公开自身的因子数据,然而各方均希望通过数据合作提升模型性能,因此,需要一种兼顾数据隐私性与可用性的技术,这与联邦学习技术的背景不谋而合。多方合作的因子模型中,各方数据差异性主要体现在因子层面,即数据集的特征的样本空间重合,而特征空间差异较大,符合纵向联邦学习范式。

为了联邦学习应用于因子模型的有效性,本文选取部分经典的股票因子构建因子池,在该因子池特征空间随机抽样,模拟各方数据集。随后在联邦学习框架下,模拟各个参与方参与联邦因子模型训练的过程,并按照预测收益率构建多空对冲投资组合,使用算法包括神经网络、线性模型以及树模型。最终,将联邦因子模型与各方本地单独训练模型进行对比,结果表明无论是模型预测涨跌能力还是最终投资组合绩效,平均而言,联邦因子模型优于各方本地单独训练模型,再一次印证了联邦学习应用于因子模型的合理性与有效性。

多方合作的因子模型牵涉到多方利益,联邦学习的参与方不会无条件地参与学习中,需要一定的激励设计以弥补联邦学习中消耗的资源,本文针对联邦因子模型场景进行演化博弈建模,梳理出利益相关主体,即联邦平台、因子数据提供方以及联邦模型使用方,对三方之间的利益关系进行刻画,分析演化稳定策略的存在性以及存在条件。分析得到四个演化稳定策略,分别对应联邦因子模型合作机制中发展初期阶段、过渡阶段以及成熟阶段。最后本文对演化系统的影响因素进行分析,通过提高模型使用方对数据提供方支付报酬的比例,将会吸引数据提供方更积极参与其中,加快博弈模型的收敛速度;此外,联邦平台对参与方正面行为激励与负面行为惩罚,也会加快博弈模型的收敛速度。

本文研究过程中,使用联邦学习框架实验模拟了多方参与的因子模型合作,目前虽然已有诸多研究将联邦学习激励机制在算法层面结合,但是本文没有将因子模型的激励机制加入联邦学习算法中。此外,未来的研究针对多方参与的联邦模型,演化博弈模型中各方主体行为、利益机制的影响因素可以更加深入细化。

参考文献

- [1] Anagnostopoulos, I,2018: Fintech and regtech: Impact on regulators and banks [J]. Journal of Economics and Business, 100: 7-25.
- [2] Bali, T G, Engle, R F, Murray, S,2016: Empirical asset pricing: The cross section of stock returns [M]. John Wiley & Sons.
- [3] Barber, B M, Odean, T,2008: All that glitters: The effect of attention and news on the buying behavior of individual and institutional investors [J]. The review of financial studies, 21(2): 785-818.
- [4] Bowles, B, Reed, A V, Ringgenberg, M C, et al.,2023: Anomaly time [J]. Available at SSRN 3069026.
- [5] Carhart, M M,1997: On persistence in mutual fund performance [J]. The Journal of finance, 52(1): 57-82.
- [6] Chen, L, Pelger, M, Zhu, J,2024: Deep learning in asset pricing [J]. Management Science, 70(2): 714-750.
- [7] Cochrane, J H,2011: Presidential address: Discount rates [J]. The Journal of finance, 66(4): 1047-1108.
- [8] Cohen, L, Malloy, C, Nguyen, Q,2020: Lazy prices [J]. The Journal of Finance, 75(3): 1371-1415.
- [9] Da, Z, Huang, X, Jin, L J,2021: Extrapolative beliefs in the cross-section: What can we learn from the crowds? [J]. Journal of Financial Economics, 140(1): 175-196.
- [10] Fama, E F, French, K R,1993: Common risk factors in the returns on stocks and bonds [J]. Journal of financial economics, 33(1): 3-56.
- [11] Fama, E F, French, K R,2015: A five-factor asset pricing model [J]. Journal of financial economics, 116(1): 1-22.
- [12] Green, J, Hand, J R, Zhang, X F,2017: The characteristics that provide independent information about average US monthly stock returns [J]. The Review of Financial Studies, 30(12): 4389-4436.
- [13] Green, T C, Huang, R, Wen, Q, et al.,2019: Crowdsourced employer reviews

- and stock returns [J]. Journal of Financial Economics, 134(1): 236-251.
- [14] Grinblatt, M, Titman, S, Wermers, R,1995: Momentum investment strategies, portfolio performance, and herding: A study of mutual fund behavior [J]. The American economic review: 1088-1105.
- [15] Gu, S, Kelly, B, Xiu, D,2020: Empirical asset pricing via machine learning [J]. The Review of Financial Studies, 33(5): 2223-2273.
- [16] Gu, S, Kelly, B, Xiu, D,2021: Autoencoder asset pricing models [J]. Journal of Econometrics, 222(1): 429-450.
- [17] Harvey, C R, Liu, Y, Zhu, H,2016: ... and the cross-section of expected returns [J]. The Review of Financial Studies, 29(1): 5-68.
- [18] Hou, K, Mo, H, Xue, C, et al.,2019: Which factors? [J]. Review of Finance, 23(1): 1-35.
- [19] Hou, K, Xue, C, Zhang, L,2020: Replicating anomalies [J]. The Review of financial studies, 33(5): 2019-2133.
- [20] Hou, K, Xue, C, Zhang, L,2015: Digesting anomalies: An investment approach [J]. The Review of Financial Studies, 28(3): 650-705.
- [21] Hu, R, Gong, Y,2020: Trading data for learning: Incentive mechanism for on-device federated learning; proceedings of the GLOBECOM 2020-2020 IEEE Global Communications Conference, F. IEEE
- [22] Huang, L, Dou, Y, Liu, Y, et al.,2021: Toward a research framework to conceptualize data as a factor of production: The data marketplace perspective [J]. Fundamental Research, 1(5): 586-594.
- [23] Jiang, F, Tang, G, Zhou, G,2018: Firm characteristics and Chinese stocks [J]. Journal of Management Science and Engineering, 3(4): 259-283.
- [24] Kaissis, G A, Makowski, M R, Rückert, D, et al.,2020: Secure, privacy-preserving and federated machine learning in medical imaging [J]. Nature Machine Intelligence, 2(6): 305-311.
- [25] Kelly, B T, Pruitt, S, Su, Y,2019: Characteristics are covariances: A unified model of risk and return [J]. Journal of Financial Economics, 134(3): 501-524.
- [26] Khan, L U, Pandey, S R, Tran, N H, et al.,2020: Federated learning for edge networks: Resource optimization and incentive mechanism [J]. IEEE

- Communications Magazine, 58(10): 88-93.
- [27] Kim, K-J,2003: Financial time series forecasting using support vector machines [J]. Neurocomputing, 55(1-2): 307-319.
- [28] Kostant, P C,1999: Exit, voice and loyalty in the course of corporate governance and counsel's changing role [J]. The Journal of Socio-Economics, 28(3): 203-246.
- [29] Kozak, S, Nagel, S, Santosh, S,2020: Shrinking the cross-section [J]. Journal of Financial Economics, 135(2): 271-292.
- [30] Lee, C M, So, E C,2015: Alphanomics: The informational underpinnings of market efficiency [J]. Foundations and Trends® in Accounting, 9(2-3): 59-258.
- [31] Lee, C M, Sun, S T, Wang, R, et al.,2019: Technological links and predictable returns [J]. Journal of Financial Economics, 132(3): 76-96.
- [32] Leei, S,2018: FinTech: ecosystem, businessmodels, invest mentdecisions, andchallenges [J]. Businesshorizons, 61(1): 35r46.
- [33] Leippold, M, Wang, Q, Zhou, W,2022: Machine learning in the Chinese stock market [J]. Journal of Financial Economics, 145(2): 64-82.
- [34] Li, Q, Wen, Z, Wu, Z, et al.,2021: A survey on federated learning systems: Vision, hype and reality for data privacy and protection [J]. IEEE Transactions on Knowledge and Data Engineering.
- [35] Liu, Y, Kang, Y, Zou, T, et al.,2024: Vertical Federated Learning: Concepts, Advances, and Challenges [J]. IEEE Transactions on Knowledge and Data Engineering.
- [36] Markowitz, H,1952: PORTFOLIO SELECTION* [J]. The Journal of Finance, 7(1): 77-91.
- [37] Mclean, R D, Pontiff, J,2016: Does academic research destroy stock return predictability? [J]. The Journal of Finance, 71(1): 5-32.
- [38] McMahan, B, Moore, E, Ramage, D, et al.,2017: Communication-efficient learning of deep networks from decentralized data; proceedings of the Artificial intelligence and statistics, F. PMLR
- [39] Nagel, S,2021: Machine learning in asset pricing [M]. Princeton University Press.

- [40] Novy-Marx, R,2013: The other side of value: The gross profitability premium [J]. Journal of financial economics, 108(1): 1-28.
- [41] Qiao, F,2019: Replicating anomalies in China [J]. Available at SSRN 3263990.
- [42] Ross, S A,2013: The arbitrage theory of capital asset pricing [M]. Handbook of the fundamentals of financial decision making: Part I. World Scientific: 11-30.
- [43] Selten, R, Selten, R,1988: A note on evolutionarily stable strategies in asymmetric animal conflicts [M]. Springer.
- [44] Sharpe, W F,1964: Capital asset prices: A theory of market equilibrium under conditions of risk [J]. The journal of finance, 19(3): 425-442.
- [45] Sirgy, M J,2002: Measuring corporate performance by building on the stakeholders model of business ethics [J]. Journal of business ethics, 35: 143-162.
- [46] Smith, J M, Price, G R,1973: The logic of animal conflict [J]. Nature, 246(5427): 15-18.
- [47] Stambaugh, R F, Yu, J, Yuan, Y,2015: Arbitrage asymmetry and the idiosyncratic volatility puzzle [J]. The Journal of Finance, 70(5): 1903-1948.
- [48] Taylor, P D, Jonker, L B,1978: Evolutionary stable strategies and game dynamics [J]. Mathematical biosciences, 40(1-2): 145-156.
- [49] Voigt, P, Von Dem Bussche, A,2017: The eu general data protection regulation (gdpr) [J]. A Practical Guide, 1st Ed, Cham: Springer International Publishing, 10(3152676): 10-5555.
- [50] Zhan, Y, Li, P, Qu, Z, et al.,2020: A learning-based incentive mechanism for federated learning [J]. IEEE Internet of Things Journal, 7(7): 6360-6368.
- [51] Zheng, W, Yan, L, Gou, C, et al.,2021: Federated meta-learning for fraudulent credit card detection; proceedings of the Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence, F.
- [52] 陈琨, 李艺, 王国赛, et al.,2021: 联邦学习在金融行业的应用分析 [J]. 征信, 39(10): 29-36.
- [53] 程乐峰, 杨汝, 王晓刚, et al.,2021: 三方多策略式博弈系统的长期演化稳定均衡特性研究 [J]. 控制理论与应用, 38(10): 1631-1661.

- [54] 付俊文, 赵红,2006: 利益相关者理论综述 [J]. 首都经济贸易大学学报, (02): 16-21.
- [55] 高明, 郭施宏, 夏玲玲,2016: 大气污染府际间合作治理联盟的达成与稳定——基于演化博弈分析 [J]. 中国管理科学, 24(08): 62-70.
- [56] 侯晓辉, 王博,2021: 基于基本面分析的量化投资: 研究述评与展望 [J]. 东北师大学报(哲学社会科学版), (01): 124-131+141.
- [57] 胡春华, 陈皖, 周艳菊, et al.,2023: 基于演化博弈的直播电商监管机制研究 [J]. 管理科学学报, 26(06): 126-141.
- [58] 黄凯南,2009: 演化博弈与演化经济学 [J]. 经济研究, 44(02): 132-145.
- [59] 贾生华, 陈宏辉,2002: 利益相关者的界定方法述评 [J]. 外国经济与管理, (05): 13-18.
- [60] 姜富伟, 薛浩, 周明,2022: 大数据提升了多因子模型定价能力吗?——基于机器学习方法对我国 A 股市场的探究 [J]. 系统工程理论与实践, 42(08): 2037-2048.
- [61] 梁文雅, 刘波, 林伟伟, et al.,2022: 联邦学习激励机制研究综述 [J]. 计算机科学, 49(12): 46-52.
- [62] 林伟伟, 石方, 曾岚, et al.,2023: 联邦学习开源框架综述 [J]. 计算机研究与发展, 60(07): 1551-1580.
- [63] 马甜, 姜富伟, 唐国豪,2022: 深度学习与中国股票市场因子投资——基于生成式对抗网络方法 [J]. 经济学(季刊), 22(03): 819-842.
- [64] 邵宇, 张鹏, 苗子清, et al.,2023: 量化投资与资本市场高质量发展 [J]. 中国金融, (20): 54-55.
- [65] 吴洁, 车晓静, 盛永祥, et al.,2019: 基于三方演化博弈的政产学研协同创新机制研究 [J]. 中国管理科学, 27(01): 162-173.
- [66] 向小佳,2022: 联邦学习原理与应用 [M]. 北京: 电子工业出版社.
- [67] 谢合亮, 胡迪,2017: 多因子量化模型在投资组合中的应用——基于 LASSO 与 Elastic Net 的比较研究 [J]. 统计与信息论坛, 32(10): 36-42.
- [68] 张潇扬, 窦一凡, 张成洪, et al.,2023: 企业数据联邦学习的收益分享机制研究 [J]. 工程管理科技前沿, 42(02): 8-15.
- [69] 张宗翔, 郑大庆, 张成洪, et al.,2024: 面向应用的联邦学习研究评述: 基于“要素-过程”框架 [J]. 管理工程学报, 38(01): 14-30.

附录

基于 FATE 框架的联邦学习训练

多期自动生成 conf 文件，将各方数据上传到 FATE 并命名，并自动进行联邦训练

```
for date in date_list:
```

```
    for i in range(5):
```

```
        # 联邦因子模型训练数据在 fate 框架下上传
```

```
        train_upload_conf = {
```

```
            "namespace": "hetero",
```

```
            "head": 1,
```

```
            "partition": 8
```

```
        }
```

```
        train_upload_conf["file"] = f"data/stock_factor_{date}_{i}_train.csv"
```

```
        train_upload_conf["table_name"] = f"stock_factor_{date}_{i}_train"
```

```
        # 联邦因子模型测试数据在 fate 框架下上传
```

```
        eval_upload_conf = {
```

```
            "namespace": "hetero",
```

```
            "head": 1,
```

```
            "partition": 8
```

```
        }
```

```
        eval_upload_conf["file"] = f"data/stock_factor_{date}_{i}_eval.csv"
```

```
        eval_upload_conf["table_name"] = f"stock_factor_{date}_{i}_eval"
```

```
        with open("train_upload_conf.json", 'w', encoding='utf-8') as f:
```

```
            json.dump(train_upload_conf, f)
```

```
        with open("eval_upload_conf.json", 'w', encoding='utf-8') as f:
```

```
            json.dump(eval_upload_conf, f)
```

```
# 调用 fate pipeline
os.system('flow data upload -c train_upload_conf.json')
os.system('flow data upload -c eval_upload_conf.json')

conf_file_name = "fate_scureboost_regression_conf.json"
dsl_file_name = "fate_scureboost_regression_dsl.json"

for date in date_list:
    for i in range(5):
        with open("fate_scureboost_regression_proto_conf.txt",'r',encoding='utf-8')
as load_f:
            conf = json.load(load_f)

            conf["role_parameters"]["guest"]["args"]["data"]["train_data"] = [{"name":
f'stock_factor_{date}_0_train', "namespace": "hetero"}]
            conf["role_parameters"]["guest"]["args"]["data"]["eval_data"] = [{"name":
f'stock_factor_{date}_0_eval', "namespace": "hetero"}]

            conf["role_parameters"]["host"]["args"]["data"]["train_data"] = [{"name":
f'stock_factor_{date}_{i}_train', "namespace": "hetero"} for i in range(1, 5)]
            conf["role_parameters"]["host"]["args"]["data"]["eval_data"] = [{"name":
f'stock_factor_{date}_{i}_eval', "namespace": "hetero"} for i in range(1, 5)]
            conf["role_parameters"]["host"]["dataio_0"]["with_label"] = [False for i in
range(5)]
            conf["role_parameters"]["host"]["dataio_0"]["output_format"] = ['dense' for
i in range(5)]

            with open(conf_file_name, 'w', encoding='utf-8') as f:
```

```
json.dump(conf, f)
```

```
# 调用 Fate Flow 构建联邦学习任务
```

```
os.system(f'flow job submit -d {dsl_file_name} -c {conf_file_name}')
```

生成训练数据、各方本地训练对比

```
def train(training_X, training_Y, testing_X, method='rf'):
```

```
    if method in ['rf', 'lr', 'svr', 'dt', 'rg', 'ls']:
```

```
        if method == 'rf':
```

```
            from sklearn.ensemble import RandomForestRegressor
```

```
            regressor = RandomForestRegressor(n_estimators=200)
```

```
        elif method == 'lr':
```

```
            from sklearn.linear_model import LinearRegression
```

```
            regressor = LinearRegression()
```

```
        elif method == 'svr':
```

```
            from sklearn.svm import SVR
```

```
            regressor = SVR(kernel='rbf')
```

```
        elif method == 'dt':
```

```
            from sklearn.tree import DecisionTreeRegressor
```

```
            regressor = DecisionTreeRegressor(random_state = 0)
```

```
        elif method == 'rg':
```

```
            from sklearn.linear_model import Ridge
```

```
            regressor = Ridge(alpha=0.5, fit_intercept=True)
```

```
        elif method == 'ls':
```

```
            from sklearn.linear_model import Lasso
```

```
            regressor = Lasso(alpha=0.05, fit_intercept=True)
```

```
    regressor.fit(training_X, training_Y)
```

```
y_pred = regressor.predict(testing_X)
return y_pred
elif method == 'xgb':
    import xgboost as xgb
    regressor = xgb.XGBRegressor(
        n_estimators=200,
        learning_rate=0.08,
        subsample=0.75,
        colsample_bytree=1,
        max_depth=25,
        gamma=0,
    )
    regressor.fit(training_X, training_Y)
    y_pred = regressor.predict(testing_X)
    return y_pred
elif method == 'nn':
    x = torch.from_numpy(training_X).float()
    y = torch.from_numpy(training_Y).float()

    test_x = torch.from_numpy(testing_X).float()

    class Net(nn.Module):
        def __init__(self,n_input,n_hidden,n_output):
            super(Net,self).__init__()
            self.hidden1 = nn.Linear(n_input,n_hidden)
            self.hidden2 = nn.Linear(n_hidden,n_hidden)
            self.hidden3 = nn.Linear(n_hidden,n_hidden)
            self.predict = nn.Linear(n_hidden,n_output)
        def forward(self,input):
            out = self.hidden1(input)
            out = F.relu(out)
```

```
        out = self.hidden2(out)
        out = F.relu(out)
        out = self.hidden3(out)
        out = F.sigmoid(out)
        out = self.predict(out)

    return out.squeeze(-1)

net = Net(x.shape[1], 20, 1)
# print(net)

optimizer = torch.optim.SGD(net.parameters(), lr = 0.05)
loss_func = torch.nn.MSELoss()

# for t in tqdm(range(2000)):
for t in range(2000):
    y_pred = net(x)
    loss = loss_func(y_pred, y)
    # if t%100 == 0:
    #     print(loss)
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
    return net(test_x).detach().numpy()

client_factor_lst = []
factors = list(data.iloc[:, 2:-2].columns)
for client in range(client_num):
    client_factor_lst.append(random.sample(factors, client_sample_num))

for i in tqdm(range(window_len, len(mon_lst))):
```

```

# print(i-window_len, i) # 前 window_len 个月作为训练数据
print('训练集: ', mon_lst[i-window_len] + '-' + mon_lst[i])
# 获取过去入选沪深 300 的票
stock_pool = set()
for mon in mon_lst[i-window_len:i]:
    stock_pool = set(hs300_cons[mon]) | stock_pool
stock_pool = list(stock_pool)

# training = data.loc[data['year-mon'].isin(mon_lst[i-window_len:i]) &
data['S_INFO_STOCKWINDCODE'].isin(stock_pool)]
training = data.loc[data['year-mon'].isin(mon_lst[i-window_len:i])]
training.to_csv(f'data/stock_factor_{mon_lst[i]}_{i}_train.csv')# 保存后续联邦训练所需数据

print('预测: ', mon_lst[i])
# testing = data.loc[(data['year-mon'] == mon_lst[i]) &
(data['S_INFO_STOCKWINDCODE'].isin(hs300_cons[mon_lst[i]]))]
testing = data.loc[(data['year-mon'] == mon_lst[i])]
training.to_csv(f'data/stock_factor_{mon_lst[i]}_{i}_eval.csv') # 保存后续联邦训练所需数据

tmp = testing[['S_INFO_STOCKWINDCODE', 'trade_date', 'yield']].copy()

for client in range(len(client_factor_lst)):

    client_training = training[['S_INFO_STOCKWINDCODE', 'trade_date'] +
client_factor_lst[client] + ['yield']]
    client_testing = testing[['S_INFO_STOCKWINDCODE', 'trade_date'] +
client_factor_lst[client] + ['yield']]

    training_X = client_training.iloc[:, 2:-1].values

```

```

training_Y = client_training.iloc[:, -1].values
testing_X = client_testing.iloc[:, 2:-1].values
testing_Y = client_testing.iloc[:, -1].values

# backtest_data.loc[backtest_data['year-mon'] == mon_lst[i], 'lr_pred'] =
train(training_X, training_Y, testing_X, 'lr')

sc = StandardScaler()
training_X = sc.fit_transform(training_X)
testing_X = sc.transform(testing_X)

# for algo in tqdm(['nn', 'lr', 'xgb']):
# for algo in tqdm(['nn', 'lr']):
for algo in method_list:
    tmp[f'client_{client}_{algo}_pred'] = train(training_X, training_Y,
testing_X, algo)
    tmp = tmp.copy()
    # pred_data = pd.DataFrame(train(training_X, training_Y, testing_X,
algo), columns=[f'client_{client}_{algo}_pred'])
    # tmp = pd.concat([tmp, pred_data], axis=1)

for algo in method_list:
    # print(training.columns[-2])
    # print(training.columns[2:-2])
    training_X = training.iloc[:, 2:-2].values
    training_Y = training.iloc[:, -2].values
    testing_X = testing.iloc[:, 2:-2].values

    sc = StandardScaler()
    training_X = sc.fit_transform(training_X)

```

```
testing_X = sc.transform(testing_X)
```

```
tmp[f'std_{algo}_pred'] = train(training_X, training_Y, testing_X, algo)
```

```
tmp = tmp.copy()
```

```
backtest_data = pd.concat([backtest_data, tmp])
```

组合绩效评估

```
def value_data(name='rf_pred'):
```

```
    date_x, rate = [], [[] for i in range(5)]
```

```
    for date in backtest_data['trade_date'].unique():
```

```
        tmp = backtest_data.loc[backtest_data['trade_date'] == date,
                                ['S_INFO_STOCKWINDCODE', 'yield', name]]
```

```
        # print(tmp[name].quantile(0.2), tmp[name].quantile(0.4),
        tmp[name].quantile(0.6), tmp[name].quantile(0.8))
```

```
        rate[0].append(tmp.loc[tmp[name] <= tmp[name].quantile(0.2),
                                'yield'].mean())
```

```
        rate[1].append(tmp.loc[(tmp[name] <= tmp[name].quantile(0.4)) &
                                (tmp[name] > tmp[name].quantile(0.2)), 'yield'].mean())
```

```
        rate[2].append(tmp.loc[(tmp[name] <= tmp[name].quantile(0.6)) &
                                (tmp[name] > tmp[name].quantile(0.4)), 'yield'].mean())
```

```
        rate[3].append(tmp.loc[(tmp[name] <= tmp[name].quantile(0.8)) &
                                (tmp[name] > tmp[name].quantile(0.6)), 'yield'].mean())
```

```
        rate[4].append(tmp.loc[tmp[name] > tmp[name].quantile(0.8),
                                'yield'].mean())
```

```
    date_x.append(str(date))
```

```
    val = (np.array(rate)+1).cumprod(axis=1)
```

```
    date_x = pd.to_datetime(date_x)
```

```
    return date_x, val
```

```
def calc_statistic():
    for algo in method_list:
        sp_list = []
        for c in range(client_num):
            date_x, val = value_data(f'client_{c}_{algo}_pred')
            sharpe = (val[4]-val[0])[-1] / np.std(val[4]-val[0])
            sp_list.append(sharpe)
        print(f'{algo} client avg sharpe ratio: {np.mean(sp_list)}')

        date_x, val = value_data(f'std_{algo}_pred')
        sharpe = (val[4]-val[0])[-1] / np.std(val[4]-val[0])
        print(f'{algo} std sharpe ratio: {sharpe}')

        date_x, val = value_data(f'federated_{algo}_pred')
        sharpe = (val[4]-val[0])[-1] / np.std(val[4]-val[0])
        print(f'{algo} federated sharpe ratio: {sharpe}\n')
```

演化博弈

#各博弈主体动态复制方程

```
def P(x, y, z):
    return x * (1-x) * ((1-p['a']) * (p['Ruse']-p['Rdep']) + y*p['Vg'] + z*p['Ause'] +
y*p['Vb'])

def B(x, y, z):
    return y * (1-y) * (p['Rg'] - p['Rb'] - p['Cg'] + p['Fpp'] + p['Fpm'] + z*p['Ag'] +
z*p['Pb'] - x*p['Vg'])

def U(x, y, z):
    return z * (1-z) * (p['F'] - p['Cp'] - x*p['Ause'] - y*p['Ag'])
```

#initX-x 初始值

```

#initY-y 初始值
#dt-步长
#epoch-迭代次数
def calculateValue(initX, initY, initZ, dt, epoch):
    x_t, y_t, z_t = [], [], []
    #演化初始赋值
    x_t.append(initX)
    y_t.append(initY)
    z_t.append(initZ)

    #微量计算及 append
    for index in range(epoch):
        temp_x = x_t[-1] + (P(x_t[-1], y_t[-1], z_t[-1])) * dt
        temp_y = y_t[-1] + (B(x_t[-1], y_t[-1], z_t[-1])) * dt
        temp_z = z_t[-1] + (U(x_t[-1], y_t[-1], z_t[-1])) * dt

        x_t.append(temp_x)
        y_t.append(temp_y)
        z_t.append(temp_z)
    return (x_t, y_t, z_t)

D=[]
#随机生成初始点
for index in range(100):
    init_x, init_y, init_z = np.random.rand(3)
    #步长, 迭代次数
    d=calculateValue(init_x, init_y, init_z, 0.005, 10000)
    D.append(d)

fig = plt.figure(figsize=(7,7))
ax = plt.axes(projection='3d')

```

```
ax.set_xlabel('$x$')
ax.set_ylabel('$y$')
ax.set_zlabel('$z$')

for x, y, z in D:
    ax.plot3D(x, y, z)
plt.savefig('111.png', dpi=200, pad_inches=0)
```